MDD303 Probabilités

CONTENTS

1 Le modèle probabiliste **7**

1.1 Événements . . . 7
1.2 Probabilité . . . 7
1.3 Tribu borélienne . . . 8
1.4 Les variables aléatoires . . . 9
1.5 La loi d'une v.a. . . . 9
1.6 Espérance . . . 9
1.7 Variance . . . 10

2 Mesure de Lebesgue et Lois de Probabilité **11**

2.1 La mesure de Lebesgue . . . 11
2.2 Loi uniforme sur $[0, 1]$ . . . 12
2.3 Lois à densité . . . 12
2.4 Classification des lois sur $\mathbb{R}$ . . . 12
2.5 L'intégrale de Lebesgue . . . 13
2.6 Formule de transfert . . . 13
2.6.1 Application à l'espérance et la variance . . . 14
2.7 Méthode de la fonction muette . . . 15

3 Indépendance **17**

3.1 Tribu engendrée par une variable aléatoire . . . 17
3.2 Définitions fondamentales . . . 17
3.2.1 Indépendance d'événements . . . 17
3.2.2 Indépendance de variables aléatoires . . . 17
3.2.3 Indépendance de sous-tribus . . . 18
3.2.4 Liens entre les définitions . . . 18
3.3 Variables aléatoires générales . . . 18
3.4 Lois Produits . . . 18
3.4.1 Construction de variables indépendantes . . . 19
3.4.2 Application : variables i.i.d. . . . 19
3.5 Regroupement par blocs . . . 20
3.6 Espérance et indépendance . . . 21
3.7 Covariance . . . 22

4 Suites infinies de variables aléatoires **23**
4.1 Modes de convergence . . . 23
4.2 Liens entre convergences . . . 23
4.3 Exemples . . . 25
4.4 Indépendance pour une suite infinie . . . 26
4.5 Le modèle analytique pour le jeu de pile ou face . . . 26
4.6 Marche aléatoire sur les entiers . . . 27

5 Transience et récurrence des marches **29**
5.1 Premier critère de récurrence . . . 29
5.2 Le lemme de Borel-Cantelli . . . 30
5.2.1 Application: Le singe et Shakespeare . . . 31
5.3 Un second critère de récurrence . . . 31
5.4 Application aux marches sur $\mathbb{Z}^d$ . . . 33
5.4.1 La marche sur $\mathbb{Z}$ . . . 33
5.4.2 La marche symétrique sur $\mathbb{Z}^2$ . . . 33
5.4.3 La marche symétrique sur $\mathbb{Z}^d, d \geq 3$ . . . 33

6 Le problème des signes aléatoires **35**
6.1 Le problème . . . 35
6.2 Convergence dans L^2 . . . 35
6.3 La loi du 0-1 de Kolmogorov . . . 36
6.4 Un résultat d'approximation . . . 36
6.5 Inégalité de Kolmogorov . . . 37
6.6 Convergence de séries de v.a. indépendantes . . . 38

7 Les lois des grands nombres **39**
7.1 Inégalités fondamentales . . . 39
7.1.1 Inégalité de Markov . . . 39
7.1.2 Inégalité de Bienaymé-Chebyshev . . . 39
7.2 La loi faible des grands nombres . . . 40
7.3 La loi forte des grands nombres . . . 41
7.4 Critère de Kolmogorov . . . 42

8 Convergence en loi **45**
8.1 Définition . . . 45
8.2 La fonction de répartition . . . 46
8.3 Convergence en loi et fonctions de répartition . . . 48

9 Les fonctions caractéristiques **51**
9.1 Définitions . . . 51
9.2 Propriétés . . . 52
9.3 Exemples classiques . . . 53
9.3.1 Récapitulatif . . . 54
9.4 Théorème d'injectivité . . . 55

10 Théorème Central Limite **57**
10.1 Le théorème de Paul Lévy . . . 57
10.2 Moments . . . 58
10.3 Convolution . . . 59
10.4 Théorème Central Limite . . . 60

11 Processus de Poisson **63**
11.1 Introduction et Motivation . . . 63
11.2 Hypothèses du modèle . . . 63
11.3 Construction d'un modèle discret . . . 63
11.4 Convergence vers la loi de Poisson . . . 64
11.5 Instants de Saut . . . 65
11.6 Le Processus de Poisson Continu . . . 66
11.6.1 Définition à partir des instants de saut . . . 66
11.7 Applications . . . 67
11.7.1 Application 1 : Bombardements de Londres (WWII) . . . 67
11.7.2 Application 2 : Problème d'Autobus . . . 68

CHAPTER 1

LE MODÈLE PROBABILISTE

Nous considérons un espace aléatoire. Nous notons Ω l'ensemble des résultats possibles : c'est un ensemble quelconque a priori.

1.1 Événements

Un événement associé à l'expérience aléatoire est un ensemble de résultats dont on peut calculer la probabilité. Notons $\mathcal{F}$ la collection de tous les événements. Ainsi, $\mathcal{F} \subset \mathcal{P}(\Omega)$, l'ensemble des parties de Ω. Nous demandons en fait que $\mathcal{F}$ soit une tribu ou σ-algèbre sur Ω.

Definition 1.1.1 (Tribu ou σ-algèbre)**.** Une tribu ou σ-algèbre sur Ω est une collection $\mathcal{F}$ de parties de Ω qui vérifie:

- $\Omega \in \mathcal{F}$
- Si $A \in \mathcal{F}$, alors $A^c \in \mathcal{F}$ (stabilité par passage au complémentaire).
- Si $(A_n)_{n\in\mathbb{N}}$ est une suite d'éléments de $\mathcal{F}$, alors leur union $\bigcup_{n\in\mathbb{N}} A_n$ est aussi dans $\mathcal{F}$ (stabilité par union dénombrable).

Remark 1.1.2. Une tribu contient forcément $\emptyset$ et Ω. En effet, comme $\mathcal{F}$ est non vide, il existe $A \in \mathcal{F}$. Par stabilité par passage au complémentaire, $A^c \in \mathcal{F}$. Par stabilité par union, $A \cup A^c = \Omega \in \mathcal{F}$. Finalement, $\Omega^c = \emptyset \in \mathcal{F}$.

Remark 1.1.3 (Rappel)**.** Deux événements A et B sont dits disjoints ou incompatibles s'ils ne peuvent arriver simultanément, c'est-à-dire si $A \cap B$ est l'événement impossible $\emptyset$.

1.2 Probabilité

Soit Ω un ensemble équipé d'une tribu $\mathcal{F}$.

Definition 1.2.1 (Probabilité)**.** Une probabilité sur $(\Omega, \mathcal{F})$ est une application $P : \mathcal{F} \to [0, 1]$ qui vérifie :

i) $P(\Omega) = 1$.

ii) Si $(A_n)_{n\in\mathbb{N}}$ est une suite d'éléments de $\mathcal{F}$ deux à deux disjoints, alors

$$P\left(\bigcup_{n\in\mathbb{N}} A_n\right) = \sum_{n\in\mathbb{N}} P(A_n).$$

Regardons dans le cas où Ω est fini. Dans ce cas, on prend toujours $\mathcal{F} = \mathcal{P}(\Omega)$. Soient A, B deux événements disjoints. Appliquons ii) à la suite $A_0 = A, A_1 = B, A_2 = A_3 = \cdots = \emptyset$. On obtient la propriété d'additivité finie :

ii') $\forall A, B$ disjoints, $P(A \cup B) = P(A) + P(B)$.

La théorie moderne des probabilités est construite avec l'axiome ii), plus fort que ii'), ne heurte pas l'intuition. Mais surtout, c'est une condition fondamentale qui permet de montrer de nombreux théorèmes limites.

Definition 1.2.2 (Espace de probabilité)**.** Un espace de probabilité est un triplet $(\Omega, \mathcal{F}, P)$ où:

- Ω est un ensemble;
- $\mathcal{F}$ est une tribu sur Ω;
- P est une probabilité définie sur $\mathcal{F}$.

Les éléments de $\mathcal{F}$ s'appellent les événements. (Axiomatique de Kolmogorov 1930).

1.3 Tribu borélienne

Soit Ω un ensemble. Si $\mathcal{F}_1, \mathcal{G}$ sont 2 tribus sur Ω, on définit leur intersection $\mathcal{F} \cap \mathcal{G} = \{A \subset \Omega; A \in \mathcal{F} \text{ et } A \in \mathcal{G}\}$. C'est encore une tribu. Plus généralement, si $(\mathcal{F}_i)_{i\in I}$ est une famille de tribus sur Ω indexée par l'ensemble I quelconque, alors $\bigcap_{i\in I} \mathcal{F}_i = \{A \subset \Omega; \forall i \in I, A \in \mathcal{F}_i\}$ est encore une tribu.

Proposition 1.3.1 (Tribu engendrée)**.** Soit $\mathcal{A}$ une collection de parties de Ω. Il existe une unique tribu $\sigma(\mathcal{A})$ qui vérifie:

i) $\mathcal{A} \subset \sigma(\mathcal{A})$.

ii) $\forall \mathcal{F}$ tribu, $\mathcal{A} \subset \mathcal{F} \implies \sigma(\mathcal{A}) \subset \mathcal{F}$.

La tribu $\sigma(\mathcal{A})$ s'appelle la tribu engendrée par $\mathcal{A}$, c'est la plus petite tribu qui contient $\mathcal{A}$.

Preuve. Considérons la tribu suivante: $\bigcap_{\mathcal{F}' \text{ tribu}, \mathcal{A}\subset\mathcal{F}'} \mathcal{F}'$. C'est une intersection de tribus, donc c'est une tribu. Elle contient $\mathcal{A}$ par construction. Elle est contenue dans toute tribu qui contient $\mathcal{A}$. C'est donc la plus petite tribu qui contient $\mathcal{A}$. □

Remark 1.3.2. C'est le procédé utilisé pour définir le sous-groupe engendré par une famille d'éléments (sev engendré...).

Definition 1.3.3 (Tribu borélienne $\mathcal{B}(\mathbb{R})$)**.** La tribu borélienne sur $\mathbb{R}$, notée $\mathcal{B}(\mathbb{R})$, est la plus petite tribu contenant les intervalles. C'est la tribu engendrée par une des familles suivantes:

- Les intervalles fermés $[a, b]$, avec $a < b \in \mathbb{R}$.
- Les intervalles ouverts $]a, b[$, avec $a < b \in \mathbb{R}$.
- Les semi-intervalles $]-\infty, \lambda]$, avec $\lambda \in \mathbb{R}$.

- Les semi-intervalles $[\lambda, +\infty[$, avec $\lambda \in \mathbb{R}$.

1.4 Les variables aléatoires

Les variables aléatoires sont les nymphes des espaces de probabilités. Une variable aléatoire (v.a.) est une fonction de l'expérience aléatoire, c'est donc a priori une application $X : \Omega \to \mathbb{R}$. Nous voulons pouvoir calculer la probabilité qu'une variable aléatoire tombe dans un intervalle arbitraire de $\mathbb{R}$. Une condition nécessaire et suffisante pour cela est de demander que X soit mesurable.

Definition 1.4.1 (Variable aléatoire)**.** Soit $(\Omega, \mathcal{F}, P)$ un espace de probabilité. Une variable aléatoire X sur $(\Omega, \mathcal{F}, P)$ est une application $X : \Omega \to \mathbb{R}$ qui est mesurable de $(\Omega, \mathcal{F})$ dans $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$, i.e.,

$$\forall B \in \mathcal{B}(\mathbb{R}), \quad X^{-1}(B) = \{\omega \in \Omega; X(\omega) \in B\} \in \mathcal{F}.$$

Ainsi, si $B \in \mathcal{B}(\mathbb{R})$, alors $X^{-1}(B)$ est un événement. On le note simplement $\{X \in B\}$ ou même $X \in B$. De manière générale, on s'efforce de simplifier les formules en enlevant la variable ω chaque fois qu'elle n'est pas indispensable.

Convention: On note les v.a. par des lettres majuscules X, Y, Z, U, V, W, et leurs valeurs correspondantes par des lettres minuscules x, y, z, u, v, w. Plus généralement, on peut considérer des v.a. à valeurs $\mathbb{C}$, dans $\mathbb{R}^n$, et en fait, dans n'importe quel ensemble équipé d'une tribu.

Definition 1.4.2 (Fonction borélienne)**.** Une fonction $f : \mathbb{R} \to \mathbb{R}$ est dite borélienne si elle est mesurable de $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$ dans $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$, i.e., si $\forall B \in \mathcal{B}(\mathbb{R}), f^{-1}(B) = \{x \in \mathbb{R} : f(x) \in B\} \in \mathcal{B}(\mathbb{R})$.

Example 1.4.3. Si X est une v.a. et f une fonction borélienne, alors $f(X)$ est encore une v.a.

Opérations sur les v.a.: Si X, Y sont des v.a. et $\alpha \in \mathbb{R}$, alors αX, $X + Y$, XY sont des v.a. Si (X_n) est une suite de v.a., alors $\liminf X_n$, $\limsup X_n$ et $\lim X_n$ (si elle existe) sont des v.a.

Lien avec la théorie de la mesure: Un espace $\mathcal{E}$ équipé d'une tribu $\mathcal{E}$ est appelé espace mesurable. Si $(E, \mathcal{E})$ et $(F, \mathcal{F})$ sont 2 espaces mesurables, une fonction $f : E \to F$ est mesurable si $\forall A \in \mathcal{F}, f^{-1}(A) \in \mathcal{E}$. Une probabilité P est une mesure (positive) de masse totale 1.

1.5 La loi d'une v.a.

Soit $(\Omega, \mathcal{F}, P)$ un espace de probabilité et soit X une v.a. définie sur Ω à valeurs dans $\mathbb{R}$.

Definition 1.5.1 (Loi d'une variable aléatoire)**.** La loi de la v.a. X, notée P_X, est la mesure de probabilité sur $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$ définie par:

$$\forall B \in \mathcal{B}(\mathbb{R}) \quad P_X(B) = P(X \in B)(= P(X^{-1}(B)) = P(\{\omega \in \Omega; X(\omega) \in B\})).$$

Insistons sur le fait que la loi d'une v.a. est une probabilité définie sur l'espace des valeurs de la v.a., dans notre cas, $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$. On dit que deux v.a. X et Y ont même loi si $P_X = P_Y$. L'objet d'intérêt primordial, quand on étudie une variable aléatoire, c'est sa loi. En effet, nous voulons évaluer les probabilités d'événements associés à la v.a. "La loi, c'est fondamental !"

1.6 Espérance

Definition 1.6.1 (Variable aléatoire étagée)**.** Une variable aléatoire $\delta : \Omega \to \mathbb{R}$ est dite 'étagée' si elle prend un nombre fini de valeurs. Elle s'écrit donc:

$$\delta = \sum_{i=1}^{n} \alpha_i \mathbb{I}_{A_i} \text{ où } \alpha_i \in \mathbb{R}, A_i \in \mathcal{F}.$$

Son espérance est son intégrale par rapport à P, donnée par $E(\delta) = \int \delta dP = \sum_{i=1}^{n} \alpha_i P(A_i)$.

Definition 1.6.2 (Espérance d'une v.a. positive)**.** Si $X : \Omega \to [0, +\infty]$ est une v.a. positive ou nulle, éventuellement elle prend la valeur $+\infty$, on définit son espérance par:

$$E(X) = \sup\{E(\delta), \delta \text{ étagée}, 0 \leq \delta \leq X\}.$$

C'est aussi l'intégrale de X par rapport à P. On note $E(X) = \int X dP$. Attention, on peut avoir $E(X) = +\infty$.

Definition 1.6.3 (Espérance d'une v.a. quelconque)**.** Si $X : \Omega \to \mathbb{R}$ est de signe quelconque, on écrit $X = X^+ - X^-$ où :

- $X^+ = \max(X, 0)$ est la partie positive.
- $X^- = -\min(X, 0)$ est la partie négative.

X^+ et X^- sont 2 v.a. positives. Lorsque $E(X^+) < \infty$ et $E(X^-) < \infty$, on pose:

$$E(X) = \int X dP = E(X^+) - E(X^-).$$

Comme de plus, $|X| = X^+ + X^-$, on a équivalence: $E(X^+) < \infty, E(X^-) < \infty \iff E(|X|) < \infty$. Dans ce cas, son espérance est $E(X) = \int X dP$. On note $\mathcal{L}^1(\Omega, \mathcal{F}, P)$ l'espace des v.a. intégrables.

1.7 Variance

Definition 1.7.1 (Variance)**.** Si X est une v.a. telle que $E(X^2) < \infty$ (ce qui implique que X est intégrable), on définit sa variance:

$$\begin{aligned} \mathrm{Var}(X) &= E[(X - E(X))^2] \\ &= E(X^2) - [E(X)]^2 \end{aligned}$$

CHAPTER 2

MESURE DE LEBESGUE ET LOIS DE PROBABILITÉ

2.1 La mesure de Lebesgue

Definition 2.1.1. Une mesure sur $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$ est une application μ de $\mathcal{B}(\mathbb{R})$ dans $[0, +\infty[$ telle que $\mu(\emptyset) = 0$ et qui est σ-additive, c'est-à-dire :

$$\forall (B_n)_{n\in\mathbb{N}} \in \mathcal{B}(\mathbb{R})^{\mathbb{N}}, \quad \left(\forall n \neq m, B_n \cap B_m = \emptyset \implies \mu\left(\bigcup_{n\in\mathbb{N}} B_n\right) = \sum_{n\in\mathbb{N}} \mu(B_n)\right)$$

Theorem 2.1.2. Il existe une unique mesure λ sur $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$ qui vérifie :

$$\forall a, b \in \mathbb{R}, a < b, \quad \lambda([a, b]) = b - a.$$

Cette mesure est appelée la **mesure de Lebesgue** et est notée λ.

Remark 2.1.3. L'existence d'une telle mesure n'est pas du tout évidente, c'est un résultat mathématique profond.

Idée de la preuve

Nous définissons pour une partie quelconque A de $\mathbb{R}$ la mesure extérieure de Lebesgue $\lambda^*(A)$ par :

$$\lambda^*(A) = \inf\left\{\sum_{i\in I}(b_i - a_i); (a_i)_{i\in I}, (b_i)_{i\in I} \text{ familles de réels tq } \forall i \in I, a_i < b_i, A \subset \bigcup_{i\in I}]a_i, b_i[\right\}$$

λ^* n'est pas une mesure, elle est sous-additive mais pas σ-additive. On montre que la restriction de λ^* à $\mathcal{B}(\mathbb{R})$ est σ-additive et on prend alors $\lambda = \lambda^*|_{\mathcal{B}(\mathbb{R})}$.

Premières propriétés

- Pour tout $x \in \mathbb{R}$, $\lambda(\{x\}) = 0$.
- Si $A \subset \mathbb{R}$ est dénombrable, alors $\lambda(A) = \sum_{x\in A} \lambda(\{x\}) = 0$ par σ-additivité.
- Il existe des boréliens C de $\mathbb{R}$ non dénombrables tels que $\lambda(C) = 0$.

2.2 Loi uniforme sur $[0,1]$

La loi uniforme sur $[0,1]$ est la mesure de probabilité P sur $([0,1], \mathcal{B}([0,1]))$ obtenue comme la restriction de la mesure de Lebesgue λ à $[0,1]$:

$$\forall B \in \mathcal{B}([0,1]), \quad P(B) = \lambda(B).$$

Nous souhaitons construire un modèle mathématique de l'expérience qui consiste à tirer un nombre au hasard dans $[0,1]$, uniformément. Nous prenons l'espace probabilisable $(\Omega, \mathcal{F}) = ([0,1], \mathcal{B}([0,1]))$. La tribu borélienne $\mathcal{B}([0,1])$ est, au choix :

- la tribu engendrée par les sous-intervalles de $[0,1]$,
- ou bien la tribu trace de $\mathcal{B}(\mathbb{R})$ sur $[0,1]$, c'est-à-dire $\{B \cap [0,1] : B \in \mathcal{B}(\mathbb{R})\}$.

Cet espace est muni de la probabilité $P = \lambda|_{[0,1]}$. Nous définissons alors une variable aléatoire X en posant :

$$\begin{aligned} X : \Omega = [0,1] &\to \mathbb{R} \\ \omega &\mapsto X(\omega) = \omega \end{aligned}$$

On dit que X est un nombre choisi au hasard uniformément dans $[0,1]$. La loi de X, notée P_X, est $\lambda|_{[0,1]}$. En effet, pour tout $B \in \mathcal{B}([0,1])$:

$$P_X(B) = P(X \in B) = P(\{\omega \in \Omega : X(\omega) \in B\}) = P(B) = \lambda(B).$$

2.3 Lois à densité

Definition 2.3.1. Une loi de probabilité μ sur $\mathbb{R}$ est dite **à densité** s'il existe une fonction f borélienne positive telle que :

$$\forall A \in \mathcal{B}(\mathbb{R}), \quad \mu(A) = \int_A f d\lambda = \int_A f(x)dx.$$

La fonction f est appelée la densité (ou une densité) de μ. Une densité est une fonction borélienne positive qui vérifie :

$$\int_{\mathbb{R}} f d\lambda = \int_{\mathbb{R}} f(x)dx = 1.$$

La densité d'une loi n'est pas unique, elle est définie à un ensemble de mesure de Lebesgue nul près. Inversement, étant donnée une fonction f borélienne positive qui vérifie cette condition, on peut construire une loi de probabilité sur $\mathbb{R}$ associée à f via la formule ci-dessus.

Example 2.3.2 (Exemples fondamentaux).

- **Loi uniforme** sur un intervalle $[a,b]$, notée $\mathcal{U}([a,b])$. C'est la loi de densité $\frac{1}{b-a}\mathbb{1}_{[a,b]}(x)$.
- **Loi exponentielle** de paramètre $\alpha > 0$, notée $\mathrm{Exp}(\alpha)$. C'est la loi de densité $\alpha e^{-\alpha x}\mathbb{1}_{\mathbb{R}_+}(x)$.
- **Loi normale** ou Gaussienne de paramètres m, σ^2, notée $\mathcal{N}(m, \sigma^2)$. C'est la loi de densité $\frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(x-m)^2}{2\sigma^2}\right)$.

2.4 Classification des lois sur $\mathbb{R}$

Un point $x \in \mathbb{R}$ est un **atome** de la loi μ si $\mu(\{x\}) > 0$. On dit que la loi μ est **diffuse** si elle n'a pas d'atomes. On distingue trois types "purs" de lois :

- **Lois discrètes :** On dit que μ est discrète s'il existe un ensemble D fini ou dénombrable tel que $\mu(D) = 1$. On a alors $\mu = \sum_{x \in D} \mu(\{x\})\delta_x$.

- **Lois à densité :** On dit que μ est à densité s'il existe une fonction borélienne $f \geq 0$ telle que $\forall A \in \mathcal{B}(\mathbb{R})$, $\mu(A) = \int_A f d\lambda$.
- **Lois singulières :** On dit que μ est singulière si elle est diffuse et s'il existe un ensemble C tel que $\mu(C) = 1$ et $\lambda(C) = 0$.

Toute mesure de probabilité sur $\mathbb{R}$ se décompose comme une combinaison convexe de ces trois types :

$$\mu = \alpha_d \mu_d + \alpha_a \mu_a + \alpha_s \mu_s$$

où μ_d, μ_a, μ_s sont respectivement discrète, à densité et singulière, et $\alpha_d, \alpha_a, \alpha_s \in [0,1]$ avec $\alpha_d + \alpha_a + \alpha_s = 1$. Cette écriture est unique.

2.5 L'intégrale de Lebesgue

Supposons que nous disposions d'une théorie de l'intégration. Étant donnée une fonction $f \geq 0$ telle que $\int_{\mathbb{R}} f(x)dx = 1$, nous pouvons définir une mesure de probabilité par $\mu(A) = \int_A f(x)dx$ pour toutes les parties A autorisées par la théorie. Par exemple, avec l'intégrale de Riemann, on ne peut intégrer que des fonctions "suffisamment régulières" (e.g. continues), et la probabilité n'est définie que sur les intervalles ou les unions finies d'intervalles. Le choix de prédilection pour la théorie des probabilités est l'intégrale de Lebesgue, qui permet d'intégrer sur tous les boréliens.

Résumé de la construction de l'intégrale de Lebesgue

1. **Fonctions étagées :** Une fonction borélienne s est dite étagée si elle prend un nombre fini de valeurs. Elle est de la forme $s = \sum_{i=1}^n a_i \mathbb{1}_{A_i}$, où $a_i \in \mathbb{R}$ et $A_i \in \mathcal{B}(\mathbb{R})$. Son intégrale par rapport à λ est :
$$\int s \, d\lambda = \sum_{i=1}^n a_i \lambda(A_i).$$
2. **Fonctions positives :** Si f est une fonction borélienne qui est positive ou nulle, l'intégrale de f par rapport à λ est :
$$\int f \, d\lambda = \sup \left\{ \int s \, d\lambda \ ; \ s \text{ étagée}, \ 0 \leq s \leq f \right\}.$$
Attention, le sup ci-dessus peut être infini.
3. **Fonctions de signe quelconque :** Soit f une fonction borélienne. On dit que f est intégrale si $\int |f| \, d\lambda < +\infty$. Dans ce cas, on décompose f en sa partie positive $f^+ = \max(f, 0)$ et sa partie négative $f^- = \max(-f, 0) = -\min(f, 0)$. On définit alors :
$$\int f \, d\lambda = \int f^+ \, d\lambda - \int f^- \, d\lambda.$$
On note $L^1(\mathbb{R}, \lambda)$ l'ensemble des fonctions λ-intégrables.

2.6 Formule de transfert

Lorsqu'on travaille avec des variables aléatoires, on effectue tout d'abord des manipulations dans l'espace probabilisé $(\Omega, \mathcal{F}, P)$. Lorsqu'il s'agit de faire intervenir les lois spécifiques des v.a., on transfère le calcul dans $\mathbb{R}$.

Proposition 2.6.1 (Formule de transfert)**.** Soit $(\Omega, \mathcal{F}, P)$ un espace probabilisé, X une variable aléatoire à valeurs dans $\mathbb{R}$, et $g : \mathbb{R} \to \mathbb{R}$ une fonction borélienne telle que $g(X)$ soit une variable aléatoire

intégrable. Alors

$$E(g(X)) = \int_\Omega g(X(\omega))\, dP(\omega) = \int_{\mathbb{R}} g(x)\, dP_X(x).$$

Preuve (Idée de la preuve)**.** La preuve se fait par étapes successives en montrant que la formule est vraie pour des classes de fonctions de plus en plus générales.

1. **Cas d'une fonction indicatrice :** Commençons par $g = \mathbb{1}_B$ où $B \in \mathcal{B}(\mathbb{R})$.

$$\begin{aligned}\int_\Omega \mathbb{1}_B(X(\omega))\, dP(\omega) &= P(\{\omega \in \Omega; X(\omega) \in B\}) \\ &= P(X \in B) = P_X(B) \\ &= \int_{\mathbb{R}} \mathbb{1}_B(x)\, dP_X(x).\end{aligned}$$

   La formule est donc vérifiée pour les fonctions indicatrices.

2. **Cas d'une fonction étagée positive :** Par linéarité de l'intégrale, la formule s'étend aux fonctions étagées positives $s = \sum a_i \mathbb{1}_{B_i}$.

3. **Cas d'une fonction borélienne positive :** On utilise un argument de convergence monotone. Soit $\mathcal{L}$ la collection des fonctions boréliennes positives pour lesquelles la formule de transfert est vraie. On montre que $\mathcal{L}$ vérifie les propriétés suivantes :

   (i) $\forall B \in \mathcal{B}(\mathbb{R}), \mathbb{1}_B \in \mathcal{L}$.

   (ii) $\forall f, g \in \mathcal{L}$, $\forall \alpha, \beta > 0$, $\alpha f + \beta g \in \mathcal{L}$ (stabilité par combinaison linéaire positive).

   (iii) $\mathcal{L}$ est stable par limite croissante : si (f_n) est une suite de fonctions de $\mathcal{L}$ telle que $f_n \leq f_{n+1}$ et $f_n \to f$ simplement, alors $f \in \mathcal{L}$.

   Par le lemme de la classe monotone, $\mathcal{L}$ contient toutes les fonctions boréliennes positives.

4. **Cas général :** Pour une fonction g de signe quelconque, on applique le résultat à sa partie positive g^+ et sa partie négative g^-.

□

2.6.1 Application à l'espérance et la variance

Soit X une variable aléatoire intégrable sur $(\Omega, \mathcal{F}, P)$ à valeurs dans $\mathbb{R}$.

Espérance L'espérance de X est définie par $E(X) = \int_\Omega X(\omega) dP(\omega)$. En appliquant la formule de transfert avec $g(x) = x$, on obtient :

$$E(X) = \int_{\mathbb{R}} x\, dP_X(x).$$

Si la loi de X, P_X, a une densité f, alors :

$$E(X) = \int_{x \in \mathbb{R}} x f(x) dx.$$

Variance Si X est de carré intégrable, sa variance est définie par $\mathrm{Var}(X) = E[(X - E(X))^2]$. En posant $m = E(X)$ et en appliquant la formule de transfert à la fonction $g(x) = (x - m)^2$, on obtient :

$$\mathrm{Var}(X) = \int_{\mathbb{R}} (x - m)^2\, dP_X(x).$$

Si la loi de X a une densité f, alors :

$$\sigma^2 = \mathrm{Var}(X) = \int_{x\in\mathbb{R}} (x-m)^2 f(x)dx = \int_{x\in\mathbb{R}} x^2 f(x)dx - m^2.$$

Example 2.6.2.
- Si $X \sim \mathrm{Exp}(\alpha)$, alors $E(X) = \frac{1}{\alpha}$ et $\mathrm{Var}(X) = \frac{1}{\alpha^2}$.
- Si $X \sim \mathcal{N}(m, \sigma^2)$, alors $E(X) = m$ et $\mathrm{Var}(X) = \sigma^2$.

2.7 Méthode de la fonction muette

La technique de base pour déterminer la loi d'une variable aléatoire X est la méthode de la fonction muette. On prend une fonction borélienne bornée $f : \mathbb{R} \to \mathbb{R}$ et on évalue $E(f(X))$. La formule de transfert, $E(f(X)) = \int_{\mathbb{R}} f(x)\, dP_X(x)$, permet d'identifier la loi P_X. Cette méthode repose sur la proposition suivante.

Proposition 2.7.1. Soient μ_1, μ_2 deux mesures de probabilité sur $\mathbb{R}$ telles que pour toute fonction $f : \mathbb{R} \to \mathbb{R}$ continue et bornée, on ait $\int_{\mathbb{R}} f d\mu_1 = \int_{\mathbb{R}} f d\mu_2$. Alors $\mu_1 = \mu_2$.

Example 2.7.2. Soit $X \sim \mathcal{U}([0,1])$ et $k \geq 1$. Quelle est la loi de $Y = X^k$?

Solution. Soit $f : \mathbb{R} \to \mathbb{R}$ une fonction continue bornée. Calculons $E(f(X^k))$.

$$\begin{aligned} E(f(X^k)) &= \int_\Omega f(X^k(\omega))dP(\omega) \\ &\overset{\text{transfert}}{=} \int_{\mathbb{R}} f(x^k)dP_X(x) && \text{avec } P_X \text{ de densité } \mathbb{1}_{[0,1]}(x) \\ &= \int_{\mathbb{R}} f(x^k)\mathbb{1}_{[0,1]}(x)dx = \int_0^1 f(x^k)dx \end{aligned}$$

Effectuons le changement de variable $y = x^k$. Alors $x = y^{1/k}$, et $dx = \frac{1}{k}y^{\frac{1}{k}-1}dy$. Les bornes d'intégration restent de 0 à 1.

$$\begin{aligned} E(f(X^k)) &= \int_0^1 f(y) \cdot \frac{1}{k}y^{\frac{1}{k}-1}dy \\ &= \int_{\mathbb{R}} f(y)\left(\frac{1}{k}y^{\frac{1}{k}-1}\mathbb{1}_{[0,1]}(y)\right)dy \end{aligned}$$

On reconnaît la forme $\int_{\mathbb{R}} f(y)g(y)dy$. Par la méthode de la fonction muette, on en déduit que la loi de X^k est une loi à densité, et sa densité est la fonction $g(y) = \frac{1}{k}y^{\frac{1}{k}-1}\mathbb{1}_{[0,1]}(y)$. □

CHAPTER 3

INDÉPENDANCE

3.1 Tribu engendrée par une variable aléatoire

Soit $(\Omega, \mathcal{F}, P)$ un espace de probabilité.

Definition 3.1.1 (Sous-tribu)**.** Une sous-tribu $\mathcal{G}$ de $\mathcal{F}$ est une tribu qui est incluse dans $\mathcal{F}$, c'est-à-dire $\mathcal{G} \subset \mathcal{F}$. Pour tout $A \in \mathcal{G}$, on a $A \in \mathcal{F}$.

Definition 3.1.2 (Tribu d'une variable aléatoire)**.** Soit X une variable aléatoire (v.a.) de $(\Omega, \mathcal{F}, P)$ dans $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$. La tribu engendrée par la v.a. X, notée $\sigma(X)$, est la plus petite tribu sur Ω pour laquelle X est mesurable. Elle est définie par :

$$\sigma(X) = \sigma(\{X^{-1}(B) \mid B \in \mathcal{B}(\mathbb{R})\})$$

Il est à noter que la collection d'ensembles $\{X^{-1}(B) \mid B \in \mathcal{B}(\mathbb{R})\}$ est elle-même une tribu.

Comme X est une v.a., pour tout $B \in \mathcal{B}(\mathbb{R})$, on a $X^{-1}(B) \in \mathcal{F}$. Par conséquent, $\sigma(X)$ est une sous-tribu de $\mathcal{F}$.

3.2 Définitions fondamentales

3.2.1 Indépendance d'événements

Definition 3.2.1. Soit $n \geq 2$. Les n événements $A_1, \ldots, A_n$ de $\mathcal{F}$ sont dits indépendants si, pour toute partie $I \subseteq \{1, \ldots, n\}$, on a :

$$P\left(\bigcap_{i \in I} A_i\right) = \prod_{i \in I} P(A_i)$$

Remark 3.2.2. Attention, "être indépendants" est une condition beaucoup plus forte que "être indépendants deux à deux".

3.2.2 Indépendance de variables aléatoires

Definition 3.2.3. Les n variables aléatoires $X_1, \ldots, X_n$ de Ω dans $\mathbb{R}$ sont dites indépendantes si, pour tous boréliens $B_1, \ldots, B_n$ de $\mathbb{R}$, on a :

$$P(X_1 \in B_1, \ldots, X_n \in B_n) = P(X_1 \in B_1) \cdots P(X_n \in B_n)$$

où la notation $P(A, B)$ signifie $P(A \cap B)$.

3.2.3 Indépendance de sous-tribus

Definition 3.2.4. Les n sous-tribus $\mathcal{F}_1, \ldots, \mathcal{F}_n$ de $\mathcal{F}$ sont dites indépendantes si, pour tout choix d'événements $A_1 \in \mathcal{F}_1, \ldots, A_n \in \mathcal{F}_n$, on a :

$$P(A_1 \cap \cdots \cap A_n) = P(A_1) \cdots P(A_n)$$

3.2.4 Liens entre les définitions

Les trois définitions précédentes sont hiérarchisées.

- Les événements $A_1, \ldots, A_n$ sont indépendants si et seulement si les variables aléatoires indicatrices $\mathbf{1}_{A_1}, \ldots, \mathbf{1}_{A_n}$ sont indépendantes.
- Les variables aléatoires $X_1, \ldots, X_n$ sont indépendantes si et seulement si les tribus qu'elles engendrent, $\sigma(X_1), \ldots, \sigma(X_n)$, sont indépendantes.

La définition basée sur les tribus est donc la plus générale. Elle permet de traiter des situations plus complexes, comme le cas de variables aléatoires à valeurs dans des espaces quelconques.

3.3 Variables aléatoires générales

Definition 3.3.1. Soit $(E, \mathcal{E})$ un espace mesurable. Une variable aléatoire à valeurs dans E est une application $X : \Omega \to E$ qui est mesurable de $(\Omega, \mathcal{F})$ dans $(E, \mathcal{E})$, c'est-à-dire :

$$\forall B \in \mathcal{E}, \quad X^{-1}(B) \in \mathcal{F}$$

Definition 3.3.2 (Loi d'une variable aléatoire)**.** La loi de X est la mesure de probabilité P_X sur $(E, \mathcal{E})$ définie par :

$$\forall B \in \mathcal{E}, \quad P_X(B) = P(X \in B) = P(X^{-1}(B))$$

Ce formalisme permet de construire des vecteurs aléatoires et même des fonctions aléatoires.

Example 3.3.3. Soient X, Y deux v.a. à valeurs dans $\mathbb{R}$. On pose $Z = (X, Y)$. Alors Z est un vecteur aléatoire de $\mathbb{R}^2$. On dit que la loi de Z admet une densité s'il existe une fonction mesurable $f : \mathbb{R}^2 \to \mathbb{R}_+$ telle que pour tout $B \in \mathcal{B}(\mathbb{R}^2)$:

$$P_Z(B) = P(Z \in B) = \iint_B f(x, y)\, dx\, dy$$

3.4 Lois Produits

Soient $(E_1, \mathcal{E}_1, \mu_1), \ldots, (E_n, \mathcal{E}_n, \mu_n)$ n espaces de probabilité. Une question naturelle se pose : existe-t-il un espace de probabilité $(\Omega, \mathcal{F}, P)$ sur lequel sont définies n variables aléatoires $X_1, \ldots, X_n$ telles que :

- $X_1, \ldots, X_n$ sont indépendantes.

- Pour tout $i \in \{1, \dots, n\}$, X_i est à valeurs dans E_i et a pour loi μ_i.

La réponse est affirmative et est fournie par la construction de la mesure produit.

3.4.1 Construction de variables indépendantes

Considérons l'espace produit cartésien $E = E_1 \times \cdots \times E_n$. On le munit de la tribu produit $\mathcal{E} = \mathcal{E}_1 \otimes \cdots \otimes \mathcal{E}_n$, qui est la tribu engendrée par les "rectangles mesurables" de la forme $B_1 \times \cdots \times B_n$, où $B_i \in \mathcal{E}_i$ pour chaque i.

Theorem 3.4.1 (Loi produit)**.** Il existe une unique mesure de probabilité μ sur l'espace mesurable $(E, \mathcal{E})$ telle que pour tous $B_1 \in \mathcal{E}_1, \dots, B_n \in \mathcal{E}_n$:

$$\mu(B_1 \times \cdots \times B_n) = \mu_1(B_1) \cdots \mu_n(B_n)$$

Cette mesure est appelée la mesure produit de $\mu_1, \dots, \mu_n$ et est notée $\mu = \mu_1 \otimes \cdots \otimes \mu_n$.

Pour répondre à notre question initiale, il suffit de poser :

- $\Omega = E = E_1 \times \cdots \times E_n$
- $\mathcal{F} = \mathcal{E} = \mathcal{E}_1 \otimes \cdots \otimes \mathcal{E}_n$
- $P = \mu = \mu_1 \otimes \cdots \otimes \mu_n$

Et de définir les variables aléatoires X_i comme les projections sur la i-ème composante, pour $i \in \{1, \dots, n\}$:

$$X_i : \Omega \to E_i, \quad \omega = (\omega_1, \dots, \omega_n) \mapsto \omega_i$$

Preuve. Vérifions que ces X_i ont les propriétés désirées.

1. **Loi de X_i :** Soit $i \in \{1, \dots, n\}$ et $B_i \in \mathcal{E}_i$. La loi de X_i est donnée par :

$$\begin{aligned} P_{X_i}(B_i) &= P(X_i \in B_i) = \mu(\{\omega = (\omega_1, \dots, \omega_n) \in \Omega \mid \omega_i \in B_i\}) \\ &= \mu(E_1 \times \cdots \times E_{i-1} \times B_i \times E_{i+1} \times \cdots \times E_n) \\ &= \mu_1(E_1) \cdots \mu_{i-1}(E_{i-1}) \mu_i(B_i) \mu_{i+1}(E_{i+1}) \cdots \mu_n(E_n) \end{aligned}$$

   Comme $\mu_j(E_j) = 1$ pour tout j, on obtient $P_{X_i}(B_i) = \mu_i(B_i)$. Donc X_i a bien pour loi μ_i.

2. **Indépendance des X_i :** Soient $B_1 \in \mathcal{E}_1, \dots, B_n \in \mathcal{E}_n$. Par définition de l'indépendance :

$$\begin{aligned} P(X_1 \in B_1, \dots, X_n \in B_n) &= \mu(\{\omega = (\omega_1, \dots, \omega_n) \mid \forall i, \omega_i \in B_i\}) \\ &= \mu(B_1 \times \cdots \times B_n) \\ &= \mu_1(B_1) \cdots \mu_n(B_n) \\ &= P(X_1 \in B_1) \cdots P(X_n \in B_n) \end{aligned}$$

   Les variables $X_1, \dots, X_n$ sont donc indépendantes.

□

3.4.2 Application : variables i.i.d.

Un cas particulier important est celui où $(E_i, \mathcal{E}_i) = (\mathbb{R}, \mathcal{B}(\mathbb{R}))$ pour tout i, et où toutes les lois sont identiques : $\mu_1 = \cdots = \mu_n = \nu$. Le théorème garantit alors l'existence d'un espace de probabilité sur lequel sont définies n variables aléatoires $X_1, \dots, X_n$ **indépendantes et identiquement distribuées** (i.i.d.), de loi commune ν.

3.5 Regroupement par blocs

L'indépendance se conserve par regroupement.

Theorem 3.5.1. Soient $\mathcal{F}_1, \ldots, \mathcal{F}_n$ des sous-tribus indépendantes. Soient I et J deux parties disjointes de $\{1, \ldots, n\}$. Alors les tribus $\mathcal{G} = \sigma(\bigcup_{i \in I} \mathcal{F}_i)$ et $\mathcal{H} = \sigma(\bigcup_{j \in J} \mathcal{F}_j)$ sont indépendantes.

La preuve de ce théorème repose sur le lemme d'unicité de l'extension, aussi connu sous le nom de lemme de la classe monotone ou théorème $\pi - \lambda$ de Dynkin.

Lemma 3.5.2 (Unicité de l'extension)**.** Soient P_1 et P_2 deux mesures de probabilité sur un espace mesurable $(\Omega, \mathcal{F})$. Supposons qu'il existe une collection $\mathcal{C}$ d'événements telle que :

i) $\mathcal{C}$ engendre $\mathcal{F}$, i.e., $\sigma(\mathcal{C}) = \mathcal{F}$.

ii) $\mathcal{C}$ est stable par intersection finie (c'est un π-système), i.e., $\forall A, B \in \mathcal{C}, A \cap B \in \mathcal{C}$.

iii) P_1 et P_2 coïncident sur $\mathcal{C}$, i.e., $\forall C \in \mathcal{C}, P_1(C) = P_2(C)$.

Alors $P_1 = P_2$ (elles coïncident sur toute la tribu $\mathcal{F}$).

Preuve (Idée de la preuve du théorème)**.** On veut montrer que $\forall D \in \mathcal{G}, \forall E \in \mathcal{H}, P(D \cap E) = P(D)P(E)$.

1. On fixe d'abord un événement D dans une classe simple génératrice de $\mathcal{G}$, par exemple $D = \bigcap_{i \in I} D_i$ avec $D_i \in \mathcal{F}_i$. On suppose $P(D) > 0$.

2. On définit deux mesures de probabilité sur $(\Omega, \mathcal{H})$: $P_1(E) = P(E|D) = \frac{P(E \cap D)}{P(D)}$ et $P_2(E) = P(E)$.

3. On montre que P_1 et P_2 coïncident sur une collection $\mathcal{C}$ qui est un π-système engendrant $\mathcal{H}$. La collection des "rectangles" $E = \bigcap_{j \in J} E_j$ avec $E_j \in \mathcal{F}_j$ convient. En effet, pour un tel E :

$$\begin{aligned} P(E \cap D) &= P\left(\left(\bigcap_{j \in J} E_j\right) \cap \left(\bigcap_{i \in I} D_i\right)\right) \\ &= \left(\prod_{j \in J} P(E_j)\right)\left(\prod_{i \in I} P(D_i)\right) \quad \text{(par indépendance des } \mathcal{F}_k) \\ &= P(E)P(D) \end{aligned}$$

   Donc $P_1(E) = P(E|D) = P(E) = P_2(E)$.

4. Par le lemme d'unicité, $P_1(E) = P_2(E)$ pour tout $E \in \mathcal{H}$, ce qui signifie $P(E \cap D) = P(E)P(D)$ pour tout $E \in \mathcal{H}$ et pour D de la forme "rectangle".

5. On refait un raisonnement similaire en fixant $E \in \mathcal{H}$ et en faisant varier D dans $\mathcal{G}$.

□

Ce théorème se généralise par récurrence.

Proposition 3.5.3. Soient $\mathcal{F}_1, \ldots, \mathcal{F}_n$ des tribus indépendantes. Soient $I_1, \ldots, I_k$ des parties de $\{1, \ldots, n\}$ qui sont deux à deux disjointes. Alors les tribus $\mathcal{G}_j = \sigma(\bigcup_{i \in I_j} \mathcal{F}_i)$ pour $j = 1, \ldots, k$ sont indépendantes.

Un corollaire direct pour les variables aléatoires est le suivant :

Theorem 3.5.4 (Corollaire)**.** Soient $X_1, \ldots, X_n$ des v.a. indépendantes. Soient $I_1, \ldots, I_k$ des parties disjointes de $\{1, \ldots, n\}$. Les vecteurs aléatoires $V_j = (X_i)_{i \in I_j}$ pour $j = 1, \ldots, k$ sont indépendants.

3.6 Espérance et indépendance

L'indépendance a une conséquence très importante sur le calcul des espérances.

Proposition 3.6.1. Soient X et Y deux variables aléatoires réelles. Les deux conditions suivantes sont équivalentes :

i) X et Y sont indépendantes.

ii) Pour toutes fonctions boréliennes $f, g : \mathbb{R} \to \mathbb{R}$ telles que $f(X)$, $g(Y)$ et $f(X)g(Y)$ sont intégrables, on a :
$$E[f(X)g(Y)] = E[f(X)]E[g(Y)]$$

Preuve. **(ii) $\implies$ (i) :** Il suffit de choisir des fonctions indicatrices. Soient $A, B \in \mathcal{B}(\mathbb{R})$. On pose $f = \mathbf{1}_A$ et $g = \mathbf{1}_B$. Ces fonctions sont boréliennes et bornées, donc les v.a. $\mathbf{1}_A(X)$, $\mathbf{1}_B(Y)$ et leur produit sont intégrables. L'égalité devient :
$$E[\mathbf{1}_A(X)\mathbf{1}_B(Y)] = E[\mathbf{1}_A(X)]E[\mathbf{1}_B(Y)]$$
Ce qui se traduit par :
$$P(X \in A, Y \in B) = P(X \in A)P(Y \in B)$$
Ceci étant vrai pour tous boréliens A et B, X et Y sont indépendantes. **(i) $\implies$ (ii) :** La preuve se fait par étapes successives (principe de la classe monotone).

1. **Fonctions indicatrices :** Si $f = \mathbf{1}_A$ et $g = \mathbf{1}_B$, l'égalité est la définition de l'indépendance, comme vu ci-dessus. C'est donc vrai.

2. **Fonctions étagées positives :** Par linéarité de l'espérance, l'égalité s'étend aux fonctions étagées positives (combinaisons linéaires finies à coefficients positifs de fonctions indicatrices).

3. **Fonctions mesurables positives :** Toute fonction mesurable positive peut être approchée par une suite croissante de fonctions étagées positives. Par le théorème de convergence monotone, l'égalité passe à la limite.

4. **Fonctions intégrables générales :** On décompose $f = f^+ - f^-$ et $g = g^+ - g^-$, où f^+, f^-, g^+, g^- sont des fonctions positives. On applique le résultat précédent à chaque paire et on utilise la linéarité de l'espérance.
$$\begin{aligned}
E[f(X)g(Y)] &= E[(f^+(X) - f^-(X))(g^+(Y) - g^-(Y))] \\
&= E[f^+(X)g^+(Y) - f^+(X)g^-(Y) - f^-(X)g^+(Y) + f^-(X)g^-(Y)] \\
&= E[f^+(X)g^+(Y)] - E[f^+(X)g^-(Y)] - E[f^-(X)g^+(Y)] + E[f^-(X)g^-(Y)] \\
&= E[f^+(X)]E[g^+(Y)] - E[f^+(X)]E[g^-(Y)] - E[f^-(X)]E[g^+(Y)] + E[f^-(X)]E[g^-(Y)] \\
&= (E[f^+(X)] - E[f^-(X)])(E[g^+(Y)] - E[g^-(Y)]) \\
&= E[f(X)]E[g(Y)]
\end{aligned}$$

□

Un corollaire immédiat et fondamental :

Theorem 3.6.2 (Corollaire)**.** Soient X et Y deux v.a. indépendantes telles que $E[|X|] < \infty$ et $E[|Y|] < \infty$. Alors XY est intégrable ($E[|XY|] < \infty$) et on a :

$$E[XY] = E[X]E[Y]$$

3.7 Covariance

Definition 3.7.1. Soient X et Y deux variables aléatoires sur $(\Omega, \mathcal{F}, P)$ qui sont intégrables, et dont le produit XY est également intégrable. La covariance de X et Y est définie par :

$$\mathrm{cov}(X, Y) = E[(X - E[X])(Y - E[Y])]$$

En développant l'expression, on obtient une formule plus pratique :

$$\begin{aligned}\mathrm{cov}(X, Y) &= E[XY - XE[Y] - YE[X] + E[X]E[Y]] \\ &= E[XY] - E[X]E[Y] - E[Y]E[X] + E[X]E[Y] \\ &= E[XY] - E[X]E[Y]\end{aligned}$$

La covariance est une mesure de la dépendance linéaire entre deux variables.

Proposition 3.7.2. Si X et Y sont indépendantes et intégrables, alors leur covariance est nulle :

$$\mathrm{cov}(X, Y) = 0$$

Preuve. Si X et Y sont indépendantes et intégrables, d'après le corollaire précédent, $E[XY] = E[X]E[Y]$. Par conséquent, $\mathrm{cov}(X, Y) = E[XY] - E[X]E[Y] = 0$. □

Remark 3.7.3. La réciproque est fausse ! Deux variables peuvent avoir une covariance nulle (on dit qu'elles sont non corrélées) sans être indépendantes. La covariance ne capture que les dépendances linéaires.

CHAPTER 4

SUITES INFINIES DE VARIABLES ALÉATOIRES

Soit $(\Omega, \mathcal{F}, P)$ un espace de probabilité.

4.1 Modes de convergence

Soit $(X_n)_{n\in\mathbb{N}}$ une suite de variables aléatoires (v.a.) définies sur $(\Omega, \mathcal{F}, P)$. Soit également X une v.a. supplémentaire définie sur $(\Omega, \mathcal{F}, P)$.

Definition 4.1.1 (Convergence presque sûre)**.** La suite $(X_n)_{n\in\mathbb{N}}$ converge presque sûrement vers X, ce que l'on note $X_n \xrightarrow{p.s.} X$, si

$$P(\{\omega \in \Omega : \lim_{n\to\infty} X_n(\omega) = X(\omega)\}) = 1.$$

Definition 4.1.2 (Convergence en moyenne d'ordre r (L^r))**.** Soit $r \geq 1$. La suite $(X_n)_{n\in\mathbb{N}}$ converge vers X dans $L^r(\Omega, P)$, ce que l'on note $X_n \xrightarrow{L^r} X$, si

$$\lim_{n\to\infty} \mathbb{E}[|X_n - X|^r] = 0.$$

Definition 4.1.3 (Convergence en probabilité)**.** La suite $(X_n)_{n\in\mathbb{N}}$ converge vers X en probabilité, ce que l'on note $X_n \xrightarrow{P} X$, si

$$\forall \varepsilon > 0, \quad \lim_{n\to\infty} P(|X_n - X| > \varepsilon) = 0.$$

4.2 Liens entre convergences

La convergence la plus difficile à établir est la convergence presque sûre.

Proposition 4.2.1. Si $X_n \xrightarrow{p.s.} X$, alors $X_n \xrightarrow{P} X$.

Preuve. Supposons $X_n \xrightarrow{p.s.} X$. Par définition, cela signifie que $P(\{\omega \in \Omega : \lim_{n\to\infty} X_n(\omega) = X(\omega)\}) =$

1. La définition de la limite d'une suite est :

$$\lim_{n\to\infty} X_n(\omega) = X(\omega) \iff \forall \varepsilon > 0, \exists N \in \mathbb{N}, \forall n > N, |X_n(\omega) - X(\omega)| < \varepsilon.$$

Pour des raisons de mesurabilité, on restreint ε aux rationnels positifs, ce qui est suffisant.

$$\begin{aligned} P(\lim_{n\to\infty} X_n = X) = 1 &\iff P\left(\forall \varepsilon \in \mathbb{Q}_+^*, \exists N \in \mathbb{N}, \forall n > N, |X_n - X| < \varepsilon\right) = 1 \\ &\iff P\left(\bigcap_{\varepsilon\in\mathbb{Q}_+^*} \bigcup_{N\in\mathbb{N}} \bigcap_{n>N} \{|X_n - X| < \varepsilon\}\right) = 1 \end{aligned}$$

Puisqu'il s'agit d'une intersection dénombrable d'événements de probabilité 1, chacun de ces événements doit avoir une probabilité de 1.

$$\implies \forall \varepsilon > 0, \quad P\left(\bigcup_{N\in\mathbb{N}} \bigcap_{n>N} \{|X_n - X| < \varepsilon\}\right) = 1$$

En passant au complémentaire, la probabilité devient 0 :

$$\forall \varepsilon > 0, \quad P\left(\left(\bigcup_{N\in\mathbb{N}} \bigcap_{n>N} \{|X_n - X| < \varepsilon\}\right)^c\right) = P\left(\bigcap_{N\in\mathbb{N}} \bigcup_{n>N} \{|X_n - X| \geq \varepsilon\}\right) = 0$$

Posons $A_N = \bigcup_{n>N}\{|X_n - X| \geq \varepsilon\}$. La suite d'événements $(A_N)_{N\in\mathbb{N}}$ est décroissante. Par continuité de la mesure de probabilité pour les suites décroissantes, on a :

$$P\left(\bigcap_{N\in\mathbb{N}} A_N\right) = \lim_{N\to\infty} P(A_N) = \lim_{N\to\infty} P\left(\bigcup_{n>N} \{|X_n - X| \geq \varepsilon\}\right) = 0.$$

Or, pour tout N, on a l'inclusion $\{|X_N - X| \geq \varepsilon\} \subset \bigcup_{n>N}\{|X_n - X| \geq \varepsilon\}$. Donc, $P(|X_N - X| \geq \varepsilon) \leq P(\bigcup_{n>N}\{|X_n - X| \geq \varepsilon\})$. En passant à la limite quand $N \to \infty$, on obtient:

$$\forall \varepsilon > 0, \quad \lim_{N\to\infty} P(|X_N - X| \geq \varepsilon) = 0.$$

Ceci est la définition de la convergence en probabilité, $X_n \xrightarrow{P} X$. □

Proposition 4.2.2. Soit $r \geq 1$. Si $X_n \xrightarrow{L^r} X$, alors $X_n \xrightarrow{P} X$.

Preuve. Soit $\varepsilon > 0$. On utilise l'inégalité de Markov. Écrivons :

$$\begin{aligned} \mathbb{E}[|X_n - X|^r] &= \int_\Omega |X_n - X|^r dP \\ &= \int_{\{|X_n - X| \geq \varepsilon\}} |X_n - X|^r dP + \int_{\{|X_n - X| < \varepsilon\}} |X_n - X|^r dP \\ &\geq \int_{\{|X_n - X| \geq \varepsilon\}} |X_n - X|^r dP \\ &\geq \int_{\{|X_n - X| \geq \varepsilon\}} \varepsilon^r dP = \varepsilon^r P(|X_n - X| \geq \varepsilon). \end{aligned}$$

D'où l'on tire:

$$P(|X_n - X| > \varepsilon) \leq \frac{1}{\varepsilon^r}\mathbb{E}[|X_n - X|^r].$$

Comme $X_n \xrightarrow{L^r} X$, on a $\lim_{n\to\infty} \mathbb{E}[|X_n - X|^r] = 0$. Par conséquent,

$$\lim_{n\to\infty} P(|X_n - X| > \varepsilon) = 0,$$

ce qui prouve que $X_n \xrightarrow{P} X$. □

Proposition 4.2.3 (Compatibilité avec l'addition)**.** Si $X_n \xrightarrow{*} X$ et $Y_n \xrightarrow{*} Y$, alors $X_n + Y_n \xrightarrow{*} X + Y$, où $*$ peut être la convergence p.s., L^r (avec le même $r \geq 1$), ou en probabilité.

Preuve (Indication pour la convergence en probabilité)**.** On utilise l'inégalité triangulaire et la sous-additivité de la probabilité. Pour tout $\varepsilon > 0$:

$$\{|(X_n + Y_n) - (X + Y)| > \varepsilon\} \subset \{|X_n - X| + |Y_n - Y| > \varepsilon\} \subset \{|X_n - X| > \varepsilon/2\} \cup \{|Y_n - Y| > \varepsilon/2\}.$$

D'où,

$$P(|(X_n + Y_n) - (X + Y)| > \varepsilon) \leq P(|X_n - X| > \varepsilon/2) + P(|Y_n - Y| > \varepsilon/2).$$

Chacun des termes de droite tend vers 0 lorsque $n \to \infty$. □

Nous pouvons également traduire dans le langage des v.a. les théorèmes classiques de théorie de la mesure.

Example 4.2.4 (Théorème de convergence dominée)**.** Soit (X_n) une suite de v.a. telle que :

1. Il existe une v.a. X telle que $X_n \xrightarrow{p.s.} X$.
2. Il existe une v.a. $Y \geq 0$ intégrable ($\mathbb{E}[Y] < \infty$) telle que $|X_n| \leq Y$ p.s. pour tout n.

Alors $X_n \xrightarrow{L^1} X$, et en particulier, $\lim_{n\to\infty} \mathbb{E}[X_n] = \mathbb{E}[X]$.

4.3 Exemples

On se place sur l'espace de probabilité $(\Omega, \mathcal{F}, P) = ([0,1], \mathcal{B}([0,1]), \lambda_{|[0,1]})$, où λ est la mesure de Lebesgue.

Example 4.3.1. Considérons la suite de fonctions définie par $X_{2k}(\omega) = \mathbf{1}_{[0,1/2]}(\omega)$ et $X_{2k+1}(\omega) = \mathbf{1}_{[1/2,1]}(\omega)$ pour $k \in \mathbb{N}$. Pour tout $\omega \in [0,1]$, la suite $(X_n(\omega))$ oscille entre 0 et 1 (sauf en $\omega = 1/2$) et ne converge donc pas. Cette suite ne converge en aucun sens (p.s., L^r, ou P).

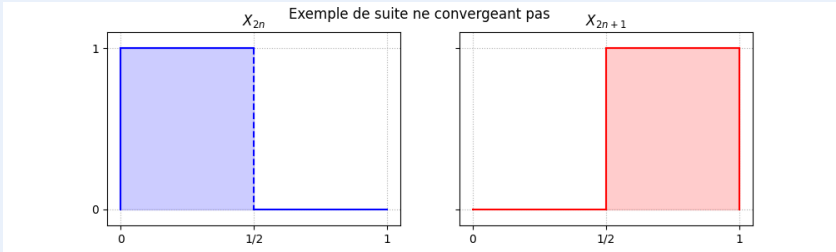

Figure 4.1: Suite (X_n) qui n'admet aucune limite.

Example 4.3.2 (La suite "machine à écrire"). Considérons la suite de v.a. (X_n) qui sont des indicatrices d'intervalles qui balaient $[0,1]$ avec une largeur qui tend vers 0. Par exemple : $X_1 = \mathbf{1}_{[0,1]}$, $X_2 = \mathbf{1}_{[0,1/2]}$, $X_3 = \mathbf{1}_{[1/2,1]}$, $X_4 = \mathbf{1}_{[0,1/3]}$, etc. Cette suite converge en probabilité vers 0, car la mesure (longueur) de l'intervalle où $X_n = 1$ tend vers 0.

$$P(|X_n - 0| > \varepsilon) = P(X_n = 1) \to 0 \quad \text{pour } 0 < \varepsilon < 1.$$

Cependant, pour tout $\omega \in [0,1]$, la suite $X_n(\omega)$ prend la valeur 1 une infinité de fois. Donc $\limsup_{n\to\infty} X_n(\omega) = 1$, tandis que $\liminf_{n\to\infty} X_n(\omega) = 0$. La limite ponctuelle n'existe pas, donc la suite ne converge pas presque sûrement. On a donc $X_n \xrightarrow{P} 0$ mais $X_n \not\xrightarrow{p.s.} 0$.

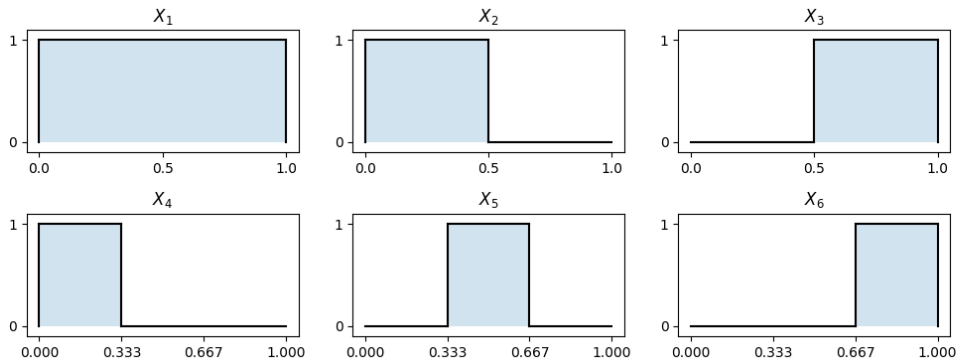

Figure 4.2: Les premiers termes de la suite "machine à écrire".

4.4 Indépendance pour une suite infinie

Definition 4.4.1. Une suite infinie de tribus $(\mathcal{F}_n)_{n\in\mathbb{N}}$ est dite indépendante (resp. d'événements, de v.a.) si toute famille finie extraite de la suite est indépendante.

Remark 4.4.2. Il y a une analogie avec la notion de liberté en algèbre linéaire.

Theorem 4.4.3 (Regroupement par blocs infinis). Soit $(X_n)_{n\in\mathbb{N}}$ une suite de v.a. indépendantes. Soit $(I_k)_{k\in\mathbb{N}}$ une partition de $\mathbb{N}$ (des parties deux à deux disjointes dont la réunion est $\mathbb{N}$). Alors les tribus $\mathcal{J}_k = \sigma(X_n, n \in I_k)$ pour $k \in \mathbb{N}$ sont indépendantes.

4.5 Le modèle analytique pour le jeu de pile ou face

Nous voulons construire un espace de probabilité $(\Omega, \mathcal{F}, P)$ sur lequel est définie une suite de v.a. $(X_n)_{n\in\mathbb{N}^*}$ de loi de Bernoulli symétrique sur $\{-1,1\}$ (parfois appelée loi de Rademacher), et qui sont toutes indépendantes. Nous prenons $(\Omega, \mathcal{F}, P) = ([0,1], \mathcal{B}([0,1]), \lambda)$, la mesure de Lebesgue sur $[0,1]$. À un nombre réel $\omega \in [0,1[$, nous associons son développement dyadique (binaire) unique, celui qui ne se termine pas par une suite infinie de 1 :

$$\omega = \sum_{n=1}^{\infty} \frac{\omega_n}{2^n}, \quad \text{où } \omega_n \in \{0,1\}.$$

Nous définissons alors, pour $n \geq 1$, la suite de variables aléatoires (X_n) par :

$$\forall \omega \in [0,1[, \quad X_n(\omega) = 2\omega_n - 1 \in \{-1,1\}.$$

Ces fonctions sont appelées les fonctions de Rademacher. On peut montrer que cette suite (X_n) répond à la question. Par exemple, $X_1(\omega) = 1$ si $\omega_1 = 1$ (i.e., $\omega \in [1/2, 1[$) et $X_1(\omega) = -1$ si $\omega_1 = 0$ (i.e., $\omega \in [0, 1/2[$). De manière générale, l'ensemble $X_n^{-1}(\{1\})$ est l'union de 2^{n-1} intervalles dyadiques de longueur $1/2^n$. La mesure totale de cet ensemble est donc $2^{n-1} \times \frac{1}{2^n} = \frac{1}{2}$. D'où $P(X_n = 1) = \lambda(\{\omega : X_n(\omega) = 1\}) = \frac{1}{2}$, et de même $P(X_n = -1) = \frac{1}{2}$.

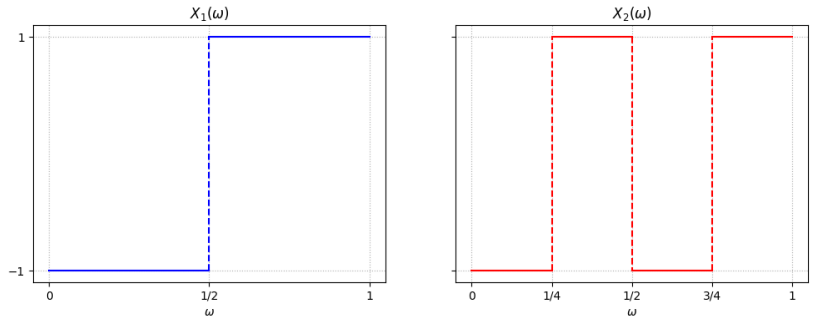

Figure 4.3: Les deux premières fonctions de Rademacher.

Pour montrer que les $(X_n)_{n\geq 1}$ sont indépendantes, il suffit de montrer que pour tous $\varepsilon_1, \ldots, \varepsilon_n \in \{-1, 1\}$, on a $P(X_1 = \varepsilon_1, \ldots, X_n = \varepsilon_n) = \prod_{i=1}^n P(X_i = \varepsilon_i)$.

$$\begin{aligned} P(X_1 = \varepsilon_1, \ldots, X_n = \varepsilon_n) &= \lambda(\{\omega \in [0, 1[: \forall i \in \{1..n\}, X_i(\omega) = \varepsilon_i\}) \\ &= \lambda(\{\omega \in [0, 1[: \forall i \in \{1..n\}, \omega_i = \frac{1 + \varepsilon_i}{2}\}) \end{aligned}$$

L'ensemble des ω dont les n premiers chiffres binaires sont fixés forme un intervalle dyadique de longueur $1/2^n$. Par exemple, si $\varepsilon_1 = 1, \varepsilon_2 = -1$, on cherche les ω avec $\omega_1 = 1, \omega_2 = 0$, c'est-à-dire $\omega \in [0.10_2, 0.11_2) = [1/2, 3/4[$. La longueur est $1/4 = 1/2^2$. Donc, $P(X_1 = \varepsilon_1, \ldots, X_n = \varepsilon_n) = \frac{1}{2^n}$. Comme $P(X_i = \varepsilon_i) = 1/2$ pour tout i, on a bien $\prod_{i=1}^n P(X_i = \varepsilon_i) = (\frac{1}{2})^n$. Les variables sont donc indépendantes. Nous possédons une suite infinie de "pièces" indépendantes.

4.6 Marche aléatoire sur les entiers

On modélise une marche aléatoire symétrique sur $\mathbb{Z}$.

- La marche démarre en 0.
- À chaque étape, on lance une pièce équilibrée.
- Pile : on fait un pas de +1 (à droite). Face : on fait un pas de -1 (à gauche).
- On réitère l'opération à partir de la nouvelle position.

Notons S_n la position du marcheur après n pas. Formellement :

$$S_0 = 0, \quad S_n = X_1 + X_2 + \cdots + X_n,$$

où les (X_i) sont une suite de v.a. i.i.d. avec $P(X_i = 1) = P(X_i = -1) = 1/2$.

$$\text{"Allumeur"} \quad \longleftrightarrow \quad 0 \quad \longleftrightarrow \quad \text{"Réverbère"}$$

Une question naturelle est : quelle est la probabilité que le marcheur repasse un jour par son point de départ (le "réverbère original")? On cherche donc à calculer :

$$P(\exists n \in \mathbb{N}^*, S_n = 0) = P\left(\bigcup_{n=1}^{\infty} \{S_n = 0\}\right).$$

Pour que $S_n = 0$, il faut autant de pas +1 que de pas -1. Le nombre total de pas n doit donc être pair. Posons $n = 2k$. On calcule d'abord la probabilité de revenir en 0 après $2k$ pas. Soit α le nombre de pas +1 et β le nombre de pas -1. On doit avoir $\alpha + \beta = 2k$ et $\alpha - \beta = 0$, ce qui implique $\alpha = \beta = k$. Le nombre de chemins de longueur $2k$ revenant à l'origine est le nombre de façons de choisir les k pas +1 parmi les $2k$ pas, soit $\binom{2k}{k}$. Le nombre total de chemins possibles de longueur $2k$ est 2^{2k}. D'où,

$$P(S_{2k} = 0) = \frac{\binom{2k}{k}}{2^{2k}}.$$

En utilisant l'approximation de Stirling, $m! \sim \sqrt{2\pi m}(m/e)^m$, on trouve :

$$P(S_{2k} = 0) \approx \frac{1}{\sqrt{\pi k}} \quad \text{pour } k \to \infty.$$

La probabilité de revenir à l'origine à un instant donné tend vers 0.

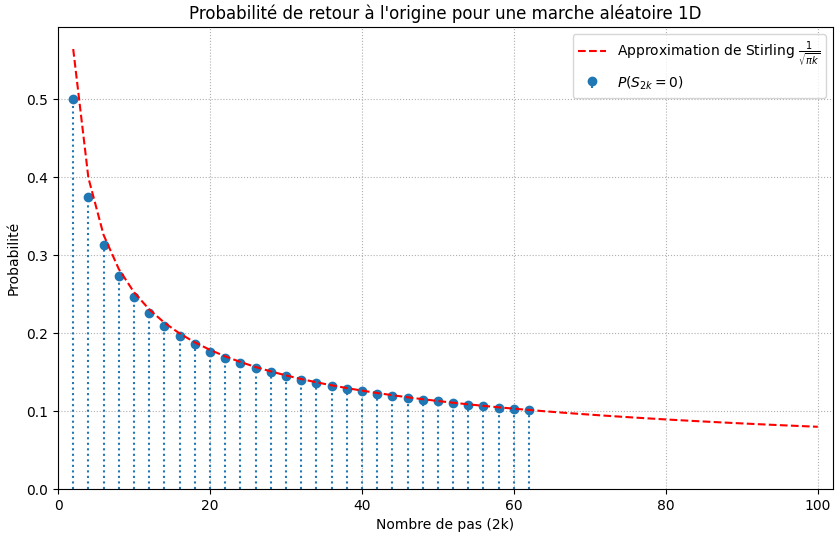

Figure 4.4: Évolution de $P(S_{2k} = 0)$ en fonction du nombre de pas.

Pour calculer la probabilité de revenir *un jour*, on décompose l'événement en une union d'événements disjoints : le premier retour à l'origine. Soit $f_{2k} = P(S_2 \neq 0, \ldots, S_{2k-2} \neq 0, S_{2k} = 0)$. La probabilité de revenir un jour est $\sum_{k=1}^{\infty} f_{2k}$.

Lemma 4.6.1. La probabilité de premier retour à l'instant $2k$ est liée à la probabilité de retour par la relation (non triviale) :

$$f_{2k} = \frac{1}{2k-1} P(S_{2k} = 0) \quad (\text{pour } k \geq 1).$$

La probabilité de revenir un jour est donc $\sum_{k=1}^{\infty} f_{2k}$. Il se trouve que cette somme vaut 1.

$$P(\exists n \in \mathbb{N}^*, S_n = 0) = \sum_{k=1}^{\infty} f_{2k} = 1.$$

La marche aléatoire simple symétrique sur $\mathbb{Z}$ est donc *récurrente* : elle est certaine de revenir à son point de départ.

CHAPTER 5

TRANSIENCE ET RÉCURRENCE DES MARCHES

Soit $d \geq 1$ et $(X_n)_{n\geq 1}$ une suite de v.a. définies sur $(\Omega, \mathcal{F}, P)$ à valeurs dans $\mathbb{Z}^d$. La marche aléatoire associée est la suite $(S_n)_{n\geq 0}$ définie par $S_0 = 0, \quad \forall n \geq 1 \quad S_n = X_1 + \cdots + X_n$. La marche aléatoire $(S_n)_{n\geq 0}$ est dite récurrente si elle repasse par 0 une infinité de fois avec probabilité 1, et transiente sinon.

5.1 Premier critère de récurrence

Proposition 5.1.1. Si la marche revient en 0 avec probabilité 1, alors elle repasse par 0 une infinité de fois avec probabilité 1.

Preuve. Soit R l'instant de la dernière visite de 0, i.e. $R = \sup\{n > 0; S_n = 0\}$. Supposons que $P(\exists n \geq 1, S_n = 0) = 1$ et regardons, pour $k \geq 1$

$$\begin{aligned} P(R = k) &= P(S_k = 0, \forall n > k, S_n - S_k \neq 0) \\ &= P(X_1 + \cdots + X_k = 0, \forall n > k, X_{k+1} + \cdots + X_n \neq 0) \end{aligned}$$

Or l'événement $\{\forall n > k, X_{k+1} + \cdots + X_n \neq 0\}$ est dans $\sigma(X_i, i \geq k+1)$. Par le théorème de regroupement par blocs, cet événement est indépendant de $\{X_1 + \cdots + X_k = 0\}$. D'où $P(R = k) = P(S_k = 0)P(\forall n > k, S_n - S_k \neq 0)$. De plus, la suite $(X_{k+1}, X_{k+2}, \dots)$ a la même loi que $(X_1, X_2, \dots)$. Donc $P(\forall n > k, S_n - S_k \neq 0) = P(\forall n \geq 1, S_n \neq 0)$. Sachant que $P(S_k = 0) \leq 1$, on a:

$$\begin{aligned} P(R = k) &\leq P(\forall n \geq 1, S_n \neq 0) \\ &\leq 1 - P(\exists n \geq 1, S_n = 0) = 1 - 1 = 0 \end{aligned}$$

Ainsi, $P(R = k) = 0$ for all $k \in \mathbb{N}^*$. Or, la probabilité que la marche visite 0 un nombre fini de fois est:

$$P(R < +\infty) = P(\bigcup_{k\in\mathbb{N}^*} \{R = k\}) \leq \sum_{k\in\mathbb{N}^*} P(R = k) = 0$$

Cela signifie que la probabilité que la marche ne revienne qu'un nombre fini de fois est nulle. Elle revient donc une infinité de fois avec probabilité 1. □

Theorem 5.1.2 (Équivalence)**.** Nous avons équivalence entre:

1. $P(\exists n \geq 1, S_n = 0) = 1$ (la marche repasse par 0).

2. $P(S_n$ visite 0 une infinité de fois$) = 1$.

Remark 5.1.3. Souvent, il est plus facile de montrer qu'un événement arrive une infinité de fois avec probabilité 1 plutôt que de montrer qu'il arrive une fois avec probabilité 1.

5.2 Le lemme de Borel-Cantelli

Soit $(\Omega, \mathcal{F}, P)$ un espace de probabilité. Soit $(A_n)_{n\in\mathbb{N}}$ une suite d'événements de $\mathcal{F}$. Nous définissons la limite inférieure et la limite supérieure de cette suite d'événements.

Definition 5.2.1.

- $\liminf A_n = \bigcup_{n\geq 0}\bigcap_{m\geq n} A_m = \{\omega \in \Omega :$ ω appartient à tous les A_n sauf un nombre fini$\}$.
- $\limsup A_n = \bigcap_{n\geq 0}\bigcup_{m\geq n} A_m = \{\omega \in \Omega : \omega$ appartient à une infinité d'$A_n\}$.

Par ailleurs, l'événement $\limsup A_n$ est souvent noté $\{A_n$ arrive infiniment souvent$\}$ ou, en abrégé, $\{A_n$ i.s.$\}$ (infiniment souvent).

Example 5.2.2.

- Soit (X_n) une suite de v.a. réelles et $B \in \mathcal{B}(\mathbb{R})$. Alors $\limsup\{X_n \in B\} = \{X_n \in B$ i.s.$\}$.
- Pour la marche aléatoire, $\limsup\{S_n = 0\} = \{S_n = 0$ i.s.$\}$.

Lemma 5.2.3 (Lemme de Borel-Cantelli)**.** Soit $(A_n)_{n\in\mathbb{N}}$ une suite d'événements.

- **Partie I:** Si la série $\sum_n P(A_n)$ converge, alors $P(A_n$ i.s.$) = 0$.
- **Partie II:** Si la série $\sum_n P(A_n)$ diverge et si les événements (A_n) sont indépendants, alors $P(A_n$ i.s.$) = 1$.

Preuve. I) Supposons que la série $\sum P(A_n)$ converge. Alors

$$P(A_n \text{ arrive infiniment souvent}) = P(\bigcap_{n\geq 0}\bigcup_{m\geq n} A_m)$$

La séquence d'événements $B_n = \bigcup_{m\geq n} A_m$ est décroissante. Par le théorème de convergence monotone:

$$P(\bigcap_{n\geq 0} B_n) = \lim_{n\to\infty} P(B_n) = \lim_{n\to\infty} P(\bigcup_{m\geq n} A_m)$$

Par la σ-additivité:

$$P(\bigcup_{m\geq n} A_m) \leq \sum_{m\geq n} P(A_m)$$

Or la série $\sum P(A_n)$ converge, donc le reste de la série tend vers 0:

$$\lim_{n\to\infty}\sum_{m\geq n} P(A_m) = 0$$

Donc, $P(A_n$ i.s.$) = 0$. **II)** Supposons que $\sum P(A_n) = +\infty$ et que les (A_n) sont indépendants. Nous

voulons montrer que $P(A_n \text{ i.s.}) = P(\bigcap_n \bigcup_{m\geq n} A_m) = 1$. Regardons le complémentaire:

$$P(\{A_n \text{ i.s.}\}^c) = P(\bigcup_n \bigcap_{m\geq n} A_m^c)$$

Soit n fixé, regardons $P(\bigcap_{m\geq n} A_m^c)$. Pour tout $N > n$:

$$P(\bigcap_{m=n}^{N} A_m^c) = \prod_{m=n}^{N} P(A_m^c) \quad \text{par indépendance}$$

$$= \prod_{m=n}^{N} (1 - P(A_m))$$

En utilisant le fait que $1 - x \leq e^{-x}$, on a

$$\prod_{m=n}^{N} (1 - P(A_m)) \leq \prod_{m=n}^{N} e^{-P(A_m)} = \exp\left(-\sum_{m=n}^{N} P(A_m)\right)$$

Comme la série $\sum P(A_n)$ diverge, $\sum_{m=n}^{N} P(A_m) \to \infty$ quand $N \to \infty$. Donc, $\exp(-\sum_{m=n}^{N} P(A_m)) \to 0$ quand $N \to \infty$. Ainsi, pour tout n, $P(\bigcap_{m\geq n} A_m^c) = 0$. Par σ-additivité,

$$P(\{A_n \text{ i.s.}\}^c) = P(\bigcup_n \bigcap_{m\geq n} A_m^c) \leq \sum_n P(\bigcap_{m\geq n} A_m^c) = \sum_n 0 = 0.$$

D'où $P(A_n \text{ i.s.}) = 1$. □

5.2.1 Application: Le singe et Shakespeare

Mettons un singe à taper à la machine à écrire. Quelle est la probabilité qu'il tape les œuvres complètes de Shakespeare? Soit $(X_n)_{n\geq 1}$ une suite i.i.d. de Bernoulli(p), $0 < p < 1$. $\forall n \geq 1$, $P(X_n = 1) = p$, $P(X_n = 0) = 1 - p$. Soit $k \geq 1$ et $(\epsilon_1, \ldots, \epsilon_k)$ une suite de 0 et de 1 fixée. Regardons l'événement $A_n = \{X_n = \epsilon_1, X_{n+1} = \epsilon_2, \ldots, X_{n+k-1} = \epsilon_k\}$. La probabilité de cet événement est $P(A_n) = p^{\sum \epsilon_i}(1-p)^{k-\sum \epsilon_i}$, qui ne dépend pas de n. Donc la série $\sum P(A_n) = +\infty$. Cependant, les (A_n) ne sont pas indépendants, on ne peut pas appliquer la partie II de Borel-Cantelli directement. Considérons les événements $B_n = A_{nk}$, pour $n \geq 1$. Par le théorème de regroupement par blocs, les (B_n) sont indépendants. Et $\sum P(B_n) = +\infty$. Par BC II, $P(B_n \text{ i.s.}) = 1$, ce qui implique que l'événement se produit une infinité de fois.

5.3 Un second critère de récurrence

Revenons à notre marche aléatoire $S_0 = 0$, $S_n = X_1 + \cdots + X_n$. Soit T l'instant du premier retour en 0: $T = \min\{n \geq 1, S_n = 0\}$, avec la convention $\inf \emptyset = +\infty$. Posons, pour $n \geq 1$, $u_n = P(S_n = 0)$ et $f_n = P(T = n)$. On pose $u_0 = 1$ et $f_0 = 0$. Pour $n \geq 1$, on peut décomposer l'événement $\{S_n = 0\}$ selon la valeur du premier temps de retour T:

$$u_n = P(S_n = 0) = P(\{S_n = 0\} \cap \bigcup_{k=1}^{n} \{T = k\}) = \sum_{k=1}^{n} P(S_n = 0, T = k)$$

$$= \sum_{k=1}^{n} P(S_1 \neq 0, \ldots, S_{k-1} \neq 0, S_k = 0, S_n = 0)$$

Par indépendance des accroissements, l'événement $\{S_n - S_k = 0\}$ est indépendant de $\{T = k\}$.

$$\begin{aligned} u_n &= \sum_{k=1}^{n} P(S_1 \neq 0, \dots, S_{k-1} \neq 0, S_k = 0) P(S_n - S_k = 0) \\ &= \sum_{k=1}^{n} P(T = k) P(S_{n-k} = 0) \\ u_n &= \sum_{k=1}^{n} f_k u_{n-k} \quad \forall n \geq 1 \end{aligned}$$

Aux suites (u_n) et (f_n), nous associons leurs séries génératrices, définies pour $s \in [0, 1)$:

$$\begin{aligned} U(s) &= \sum_{n \geq 0} u_n s^n \\ F(s) &= \sum_{n \geq 0} f_n s^n = E(s^T) \end{aligned}$$

La relation de récurrence $u_n = \sum_{k=1}^{n} f_k u_{n-k}$ est une convolution. Pour $n \geq 1$:

$$u_n s^n = \sum_{k=1}^{n} f_k u_{n-k} s^n = \sum_{k=1}^{n} (f_k s^k)(u_{n-k} s^{n-k})$$

En sommant sur $n \geq 1$:

$$\begin{aligned} \sum_{n \geq 1} u_n s^n &= \sum_{n \geq 1} \sum_{k=1}^{n} (f_k s^k)(u_{n-k} s^{n-k}) \\ U(s) - u_0 &= \left(\sum_{k \geq 1} f_k s^k \right) \left(\sum_{j \geq 0} u_j s^j \right) \\ U(s) - 1 &= F(s) U(s) \end{aligned}$$

On obtient donc la relation $U(s)(1 - F(s)) = 1$ pour $s \in [0, 1)$. En faisant tendre $s \to 1^-$, les séries étant à termes positifs, on a par le théorème de convergence monotone:

$$\begin{aligned} \lim_{s \to 1^-} U(s) &= \sum_{n \geq 0} u_n = \sum_{n \geq 0} P(S_n = 0) \\ \lim_{s \to 1^-} F(s) &= \sum_{n \geq 0} f_n = \sum_{n \geq 0} P(T = n) = P(T < +\infty) = P(\exists n \geq 1, S_n = 0) \end{aligned}$$

Ainsi, on obtient la relation:

$$\left(\sum_{n \geq 0} P(S_n = 0) \right) (1 - P(\exists n \geq 1, S_n = 0)) = 1$$

Cette égalité implique que les deux termes sont finis ou infinis en même temps. En particulier, $\sum P(S_n = 0) = +\infty$ si et seulement si $1 - P(\exists n \geq 1, S_n = 0) = 0$, c'est-à-dire $P(\exists n \geq 1, S_n = 0) = 1$. Ceci nous mène au théorème d'équivalence suivant:

Theorem 5.3.1 (Critères de récurrence)**.** Les affirmations suivantes sont équivalentes:

1. $P(\exists n \geq 1, S_n = 0) = 1$ (la marche est récurrente au sens du premier retour).
2. $P(S_n = 0 \text{ i.s.}) = 1$ (la marche est récurrente).

3. $\sum_{n=0}^{\infty} P(S_n = 0) = +\infty$.

5.4 Application aux marches sur $\mathbb{Z}^d$

5.4.1 La marche sur $\mathbb{Z}$

Soit $0 < p < 1$ et (X_n) i.i.d. de loi Ber(p) sur $\{-1, 1\}$, i.e. $P(X_n = 1) = p$ et $P(X_n = -1) = 1 - p$. Pour que $S_{2n} = 0$, il faut autant de pas $+1$ que de pas -1, soit n de chaque. $P(S_{2k+1} = 0) = 0$.

$$P(S_{2n} = 0) = \binom{2n}{n} p^n (1-p)^n$$

En utilisant l'approximation de Stirling $k! \sim \sqrt{2\pi k}(\frac{k}{e})^k$, on obtient:

$$\binom{2n}{n} \sim \frac{4^n}{\sqrt{\pi n}}$$

D'où,

$$P(S_{2n} = 0) \sim \frac{(4p(1-p))^n}{\sqrt{\pi n}}$$

La série $\sum_n P(S_{2n} = 0)$ se comporte comme une série géométrique.

- Si $p = 1/2$, $4p(1-p) = 1$ et $P(S_{2n} = 0) \sim \frac{1}{\sqrt{\pi n}}$. La série $\sum \frac{1}{\sqrt{n}}$ diverge, donc la marche symétrique sur $\mathbb{Z}$ est **récurrente**.
- Si $p \neq 1/2$, $4p(1-p) < 1$. La série $\sum \frac{(4p(1-p))^n}{\sqrt{\pi n}}$ converge, donc la marche sur $\mathbb{Z}$ est **transiente**.

5.4.2 La marche symétrique sur $\mathbb{Z}^2$

Soit (X_n) une suite de v.a. i.i.d. à valeurs dans $\{(1,0), (-1,0), (0,1), (0,-1)\}$, avec probabilité $1/4$ pour chaque. On peut montrer que:

$$P(S_{2n} = 0) \sim \frac{1}{\pi n}$$

La série $\sum \frac{1}{n}$ (série harmonique) diverge. La marche symétrique sur $\mathbb{Z}^2$ est **récurrente**.

5.4.3 La marche symétrique sur $\mathbb{Z}^d, d \geq 3$

Pour la marche symétrique sur $\mathbb{Z}^3$, on a:

$$P(S_{2n} = 0) = O(n^{-3/2})$$

La série $\sum n^{-3/2}$ converge (série de Riemann avec $p = 3/2 > 1$). La marche symétrique sur $\mathbb{Z}^3$ est **transiente**. En dimension $d > 3$, la marche symétrique dans $\mathbb{Z}^d$ est transiente, et le nombre moyen de retours en 0 est:

$$U_d = \frac{1}{(2\pi)^d} \int_{[-\pi,\pi]^d} \frac{1}{1 - \frac{1}{d}\sum_{k=1}^{d} \cos u_k} du_1 \dots du_d$$

Cet intégrale est finie pour $d \geq 3$.

CHAPTER 6

LE PROBLÈME DES SIGNES ALÉATOIRES

6.1 Le problème

Soit $(u_n)_{n\in\mathbb{N}}$ une suite (déterministe) de nombres réels. Soit $(\epsilon_n)_{n\in\mathbb{N}}$ une suite infinie i.i.d. de Bernoulli(1/2) telle que:

$$\forall n \in \mathbb{N}, \quad \mathbb{P}(\epsilon_n = -1) = \mathbb{P}(\epsilon_n = 1) = 1/2$$

La série $\sum \epsilon_n u_n$ converge-t-elle?

- Si $u_n \not\to 0$, la série ne converge pas.
- Si la série $\sum |u_n|$ est absolument convergente, alors $\sum \epsilon_n u_n$ est p.s. absolument convergente.

Regardons la série harmonique: $\sum 1/n = +\infty$.

$$\sum_{n\geq 1} \frac{(-1)^{n-1}}{n} = 1 - 1/2 + 1/3 - \cdots = \ln(2)$$

6.2 Convergence dans L^2

Proposition 6.2.1. La série de v.a. $\sum u_n \epsilon_n$ converge dans L^2 si et seulement si la série $\sum |u_n|^2$ converge.

Preuve. Posons $S_n = \sum_{k=0}^n \epsilon_k u_k$. Alors, la série $\sum \epsilon_n u_n$ converge dans L^2 ssi la suite $(S_n)_{n\in\mathbb{N}}$ converge dans L^2. L'espace $L^2(\Omega, \mathcal{F}, \mathbb{P})$ est complet pour $\|\cdot\|_2$. Ainsi, la suite $(S_n)_{n\in\mathbb{N}}$ converge ssi elle vérifie le critère de Cauchy. Soit $m < n$, regardons:

$$\begin{aligned}
\|S_n - S_m\|_2^2 &= \int |S_n - S_m|^2 d\mathbb{P} \\
&= E[(S_n - S_m)^2] \\
&= E\left[\left(\sum_{k=m+1}^n \epsilon_k u_k\right)^2\right] \\
&= E\left[\sum_{m<k,l\leq n} \epsilon_k \epsilon_l u_k u_l\right] = \sum_{m<k,l\leq n} u_k u_l E(\epsilon_k \epsilon_l)
\end{aligned}$$

Pour $k \neq l$, $E(\epsilon_k \epsilon_l) = E(\epsilon_k)E(\epsilon_l) = 0$ car les v.a. sont indépendantes et centrées. Pour $k = l$, $E(\epsilon_k^2) = 1$. Donc,

$$\|S_n - S_m\|_2^2 = \sum_{k=m+1}^{n} u_k^2 = a_n - a_m \quad \text{où } a_n = \sum_{k=0}^{n} u_k^2$$

Ainsi, la suite (S_n) est de Cauchy dans L^2 ssi la suite (a_n) est de Cauchy dans $\mathbb{R}$. □

6.3 La loi du 0-1 de Kolmogorov

Definition 6.3.1. Soit $(X_n)_{n\in\mathbb{N}}$ une suite de v.a. définies sur l'espace $(\Omega, \mathcal{F}, \mathbb{P})$. La **tribu de queue**, ou **tribu asymptotique**, associée à la suite (X_n) est la tribu:

$$\mathcal{T} = \bigcap_{n\geq 0} \sigma(X_n, X_{n+1}, \dots)$$

Un événement $A \in \mathcal{F}$ est dit **asymptotique** pour la suite (X_n) s'il est dans la tribu asymptotique.

Example 6.3.2. Les événements suivants sont asymptotiques:

- $\{\limsup X_n > 100\}$
- $\{\liminf X_n \in [0, 1]\}$
- $\{\omega : \lim X_n(\omega) \text{ existe}\}$
- $\{\omega : \sum \epsilon_n(\omega) u_n \text{ converge}\}$, qui est un événement asymptotique pour la suite $(\epsilon_n)_{n\in\mathbb{N}}$.

Theorem 6.3.3 (Loi du 0-1 de Kolmogorov)**.** Soit $(X_n)_{n\in\mathbb{N}}$ une suite de v.a. indépendantes. Soit A un événement asymptotique pour la suite (X_n). Alors $\mathbb{P}(A)$ vaut 0 ou 1.

Application au problème des signes

L'événement $\{\sum \epsilon_n u_n \text{ converge}\}$ est un événement asymptotique pour la suite (ϵ_n). Comme les (ϵ_n) sont indépendantes, la probabilité de cet événement est 0 ou 1. Soit la série converge p.s., soit elle ne converge pas p.s.

6.4 Un résultat d'approximation

La **différence symétrique** de 2 ensembles A et B est $A\Delta B = (A \cup B) \setminus (A \cap B)$.

- $A\Delta\emptyset = \emptyset\Delta A = A$
- $A\Delta A = \emptyset$
- $\forall A, B, C, \quad A\Delta(B\Delta C) = (A\Delta B)\Delta C$
- $(\mathcal{P}(\Omega), \Delta)$ est un groupe abélien.

Proposition 6.4.1. Soit $(X_n)_{n\in\mathbb{N}}$ une suite de v.a. et soit A un événement dans la tribu $\sigma(X_0, X_1, \dots)$. Alors il existe une suite d'événements $(A_n)_{n\in\mathbb{N}}$ telle que:

- $\forall n \in \mathbb{N}, \exists k(n), \quad A_n \in \sigma(X_0, \dots, X_{k(n)})$

- $\lim_{n\to\infty} \mathbb{P}(A_n \Delta A) = 0$

Remark 6.4.2. $\forall A, B, \quad |\mathbb{P}(A) - \mathbb{P}(B)| \leq \mathbb{P}(A\Delta B)$, donc on aura aussi $\lim_{n\to\infty} \mathbb{P}(A_n) = \mathbb{P}(A)$.

Preuve. Considérons $\mathcal{G}$ la collection des événements pour lesquels le résultat est vrai. On montre que $\mathcal{G}$ est une σ-algèbre. L'algèbre $\mathcal{A} = \bigcup_m \sigma(X_0, \dots, X_m)$ est contenue dans $\mathcal{G}$. En effet, si $A \in \sigma(X_0, \dots, X_m)$, il suffit de prendre $A_n = A$ pour tout n. On montre ensuite que $\mathcal{G}$ est une tribu.

- $\Omega \in \mathcal{G}$.
- Si $A \in \mathcal{G}$ et (A_n) est une suite qui approxime A, alors la suite (A_n^c) approxime A^c:
$$\mathbb{P}(A^c \Delta A_n^c) = \mathbb{P}(A\Delta A_n) \to 0$$
- Si $(A_m)_{m\geq 1}$ est une suite de $\mathcal{G}$, alors $A = \bigcup_m A_m \in \mathcal{G}$. Comme $A_m \in \mathcal{G}$, il existe $(A_{m,n})_n$ approximante pour A_m. $\forall n, \forall m \geq 1, \exists k(m,n), A_{m,n} \in \sigma(X_0, \dots, X_{k(m,n)})$ et $\lim_{n\to\infty} \mathbb{P}(A_m \Delta A_{m,n}) = 0$. Comme $\lim_{M\to\infty} \mathbb{P}(A \setminus \bigcup_{m=1}^M A_m) = 0$, $\forall M \geq 1, \exists \varphi(M)$ t.q. $\mathbb{P}(A \setminus \bigcup_{m=1}^{\varphi(M)} A_m) < 1/M$. Ensuite, $\forall m \in \{1, \dots, \varphi(M)\}$, $\exists N(M,m)$ t.q. $\forall n > N(M,m)$, $\mathbb{P}(A_m \Delta A_{m,n}) \leq \frac{1}{\varphi(M)M}$. Prenons alors $N(M) = \max\{N(M,m), 1 \leq m \leq \varphi(M)\}$ et $A'_M = \bigcup_{m=1}^{\varphi(M)} A_{m,N(M,m)}$.
$$\begin{aligned}
\mathbb{P}(A\Delta A'_M) &\leq \mathbb{P}\left(A\Delta \bigcup_{m=1}^{\varphi(M)} A_m\right) + \mathbb{P}\left(\left(\bigcup_{m=1}^{\varphi(M)} A_m\right) \Delta A'_M\right) \\
&< \frac{1}{M} + \sum_{m=1}^{\varphi(M)} \mathbb{P}(A_m \Delta A_{m,N(M,m)}) \\
&\leq \frac{1}{M} + \sum_{m=1}^{\varphi(M)} \frac{1}{\varphi(M)M} = \frac{1}{M} + \frac{1}{M} = \frac{2}{M} \to 0
\end{aligned}$$

Puisque $\mathcal{G}$ est une σ-algèbre contenant $\mathcal{A}$, $\mathcal{G}$ contient $\sigma(\mathcal{A}) = \sigma(X_0, X_1, \dots)$. □

On applique ce résultat pour prouver la loi du 0-1. Soit (X_n) indépendantes, $A \in \mathcal{T} = \bigcap_k \sigma(X_k, X_{k+1}, \dots)$. Il existe (A_n) avec $A_n \in \sigma(X_0, \dots, X_{k(n)})$ et $\lim \mathbb{P}(A\Delta A_n) = 0$. D'abord, $|\mathbb{P}(A) - \mathbb{P}(A_n)| \leq \mathbb{P}(A\Delta A_n) \to 0$, donc $\mathbb{P}(A_n) \to \mathbb{P}(A)$. De plus, $A_n \in \sigma(X_0, \dots, X_{k(n)})$ et $A \in \mathcal{T} \subset \sigma(X_{k(n)+1}, X_{k(n)+2}, \dots)$. Comme (X_n) sont indépendantes, les deux tribus sont indépendantes. Donc A et A_n aussi.
$$\mathbb{P}(A \cap A_n) = \mathbb{P}(A)\mathbb{P}(A_n) \xrightarrow{n\to\infty} \mathbb{P}(A)^2$$
Aussi, $|\mathbb{P}(A) - \mathbb{P}(A \cap A_n)| = \mathbb{P}(A \setminus A_n) \leq \mathbb{P}(A\Delta A_n) \to 0$, d'où $\lim \mathbb{P}(A \cap A_n) = \mathbb{P}(A)$. On conclut que $\mathbb{P}(A) = \mathbb{P}(A)^2$, ce qui implique $\mathbb{P}(A) \in \{0, 1\}$.

6.5 Inégalité de Kolmogorov

Theorem 6.5.1. Soient $X_1, \dots, X_n$ n v.a. indépendantes, centrées ($E(X_i) = 0$) et de variances finies. Posons $\forall k \in \{1, \dots, n\}, S_k = X_1 + \dots + X_k$. Alors $\forall \alpha > 0$,
$$\mathbb{P}(\max_{1\leq k\leq n} |S_k| \geq \alpha) \leq \frac{1}{\alpha^2} \mathrm{Var}(S_n)$$

Preuve. Pour $k \in \{1, \dots, n\}$, on introduit l'événement $A_k = \{|S_1| < \alpha, \dots, |S_{k-1}| < \alpha, |S_k| \geq \alpha\}$. Les événements (A_k) sont disjoints. Posons $A = \bigcup_{k=1}^n A_k = \{\max_{1 \leq k \leq n} |S_k| \geq \alpha\}$.

$$\begin{aligned}\mathrm{Var}(S_n) = E(S_n^2) &= \int_\Omega S_n^2 d\mathbb{P} \geq \int_A S_n^2 d\mathbb{P} \\ &= \sum_{k=1}^n \int_{A_k} S_n^2 d\mathbb{P} \quad \text{car les } A_k \text{ sont disjoints}\end{aligned}$$

De plus,

$$\begin{aligned}\int_{A_k} S_n^2 d\mathbb{P} &= \int_{A_k} (S_k + (S_n - S_k))^2 d\mathbb{P} \\ &= \int_{A_k} \left(S_k^2 + 2S_k(S_n - S_k) + (S_n - S_k)^2\right) d\mathbb{P} \\ &\geq \int_{A_k} \left(S_k^2 + 2S_k(S_n - S_k)\right) d\mathbb{P}\end{aligned}$$

Le terme $\mathbf{1}_{A_k} S_k$ est $\sigma(X_1, \dots, X_k)$-mesurable. Le terme $S_n - S_k = \sum_{j=k+1}^n X_j$ est $\sigma(X_{k+1}, \dots, X_n)$-mesurable. Par indépendance,

$$E[\mathbf{1}_{A_k} S_k (S_n - S_k)] = E[\mathbf{1}_{A_k} S_k] E[S_n - S_k] = E[\mathbf{1}_{A_k} S_k] \cdot 0 = 0$$

Donc $\int_{A_k} 2S_k(S_n - S_k) d\mathbb{P} = 0$. On a donc $\int_{A_k} S_n^2 d\mathbb{P} \geq \int_{A_k} S_k^2 d\mathbb{P}$. Sur A_k, on a $|S_k| \geq \alpha$, donc $S_k^2 \geq \alpha^2$.

$$\int_{A_k} S_k^2 d\mathbb{P} \geq \int_{A_k} \alpha^2 d\mathbb{P} = \alpha^2 \mathbb{P}(A_k)$$

En sommant sur k:

$$\mathrm{Var}(S_n) \geq \sum_{k=1}^n \alpha^2 \mathbb{P}(A_k) = \alpha^2 \mathbb{P}\left(\bigcup_{k=1}^n A_k\right) = \alpha^2 \mathbb{P}(A)$$

Ce qui donne le résultat. □

6.6 Convergence de séries de v.a. indépendantes

Theorem 6.6.1. Soit $(X_n)_{n \in \mathbb{N}}$ une suite de v.a. indépendantes, centrées et de variances finies, $\forall n, E(X_n) = 0, E(X_n^2) < \infty$. Si $\sum E(X_n^2) < \infty$, alors la série $\sum X_n$ converge p.s.

Une conséquence des résultats précédents est que, pour le problème des signes aléatoires:

$$\sum_{n \in \mathbb{N}} u_n^2 < \infty \iff \sum_{n \in \mathbb{N}} \epsilon_n u_n \text{ converge p.s.}$$

CHAPTER 7

LES LOIS DES GRANDS NOMBRES

7.1 Inégalités fondamentales

7.1.1 Inégalité de Markov

Proposition 7.1.1. Soit X une v.a. positive. Alors $\forall \lambda > 0$,

$$P(X \geq \lambda) \leq \frac{1}{\lambda} E[X].$$

Remark 7.1.2. Comme $X \geq 0$, $E[X]$ est toujours défini, éventuellement $E[X] = +\infty$.

Preuve. On a

$$\begin{aligned} E[X] = \int_\Omega X dP &= \int_{\{X \geq \lambda\}} X dP + \int_{\{X < \lambda\}} X dP \\ &\geq \int_{\{X \geq \lambda\}} X dP \quad (\text{car } X \geq 0) \\ &\geq \int_{\{X \geq \lambda\}} \lambda dP \quad (\text{car sur } \{X \geq \lambda\}, X \geq \lambda) \\ &= \lambda P(X \geq \lambda). \end{aligned}$$

En divisant par $\lambda > 0$, on obtient le résultat. □

L'inégalité de Markov permet de prouver de nombreuses inégalités plus générales.

7.1.2 Inégalité de Bienaymé-Chebyshev

Proposition 7.1.3. Soit X une v.a. qui admet un moment d'ordre 2, c'est-à-dire, $E[X^2] < +\infty$. Alors $\forall t > 0$,

$$P(|X - E[X]| \geq t) \leq \frac{1}{t^2} \mathrm{Var}(X).$$

Preuve. L'inégalité est triviale si $t \leq 0$. Soit $t > 0$. On a

$$P(|X - E[X]| \geq t) = P((X - E[X])^2 \geq t^2).$$

On applique l'inégalité de Markov à la variable aléatoire positive $Y = (X - E[X])^2$ avec $\lambda = t^2$:

$$P(Y \geq t^2) \leq \frac{E[Y]}{t^2}.$$

Or, $E[Y] = E[(X - E[X])^2] = \mathrm{Var}(X)$. D'où le résultat:

$$P(|X - E[X]| \geq t) \leq \frac{\mathrm{Var}(X)}{t^2}.$$

□

L'intérêt de cette inégalité réside dans sa simplicité et le fait qu'elle est très bien adaptée aux sommes de variables aléatoires.

7.2 La loi faible des grands nombres

Theorem 7.2.1. Soit μ une mesure de probas sur $\mathbb{R}$ qui est intégrable, c'est-à-dire $\int_{\mathbb{R}} |x| d\mu(x) < +\infty$. Soit $m = \int_{\mathbb{R}} x d\mu(x)$. Pour $n \geq 1$, soient $X_1, \ldots, X_n$ des v.a. i.i.d. de loi μ. Alors, $\forall \varepsilon > 0$,

$$\lim_{n \to \infty} P\left(\left|\frac{X_1 + \cdots + X_n}{n} - m\right| \geq \varepsilon\right) = 0.$$

Remark 7.2.2. Si (X_n) est une suite de v.a. i.i.d. de loi μ, cela s'écrit:

$$\frac{X_1 + \cdots + X_n}{n} \xrightarrow[n \to \infty]{P} m.$$

Remark 7.2.3. En fait, par la formule de transfert appliquée au vecteur $(X_1, \ldots, X_n)$, on a:

$$P\left(\left|\frac{X_1 + \cdots + X_n}{n} - m\right| \geq \varepsilon\right) = P_{\mu^{\otimes n}}\left(\{(x_1, \ldots, x_n) \in \mathbb{R}^n, \left|\frac{x_1 + \cdots + x_n}{n} - m\right| \geq \varepsilon\}\right).$$

Ainsi, la loi faible est en fait un résultat asymptotique sur la suite de lois $(\mu^{\otimes n}, n \geq 1)$. La loi ne nécessite pas d'avoir une suite i.i.d.

Preuve (Preuve (sous l'hypothèse d'un moment d'ordre 2))**.** Supposons que la loi μ admette un moment d'ordre 2. Posons $\sigma^2 = \mathrm{Var}(\mu) = \int_{\mathbb{R}} (x - m)^2 d\mu(x)$. Soit $\bar{X}_n = \frac{X_1 + \cdots + X_n}{n}$. Le calcul de l'espérance donne:

$$E[\bar{X}_n] = E\left[\frac{X_1 + \cdots + X_n}{n}\right] = \frac{1}{n}(E[X_1] + \cdots + E[X_n]) = \frac{1}{n}(n \cdot m) = m.$$

Soit $\varepsilon > 0$. En appliquant l'inégalité de Bienaymé-Chebyshev à $\bar{X}_n$:

$$P(|\bar{X}_n - m| \geq \varepsilon) \leq \frac{\mathrm{Var}(\bar{X}_n)}{\varepsilon^2}.$$

Calculons la variance:

$$\begin{aligned}
\mathrm{Var}(\bar{X}_n) &= \mathrm{Var}\left(\frac{X_1 + \cdots + X_n}{n}\right) \\
&= \frac{1}{n^2}\mathrm{Var}(X_1 + \cdots + X_n) \\
&= \frac{1}{n^2}(\mathrm{Var}(X_1) + \cdots + \mathrm{Var}(X_n)) \quad \text{(par indépendance)} \\
&= \frac{1}{n^2}(n \cdot \sigma^2) \quad \text{(car les lois sont identiques)} \\
&= \frac{\sigma^2}{n}.
\end{aligned}$$

D'où

$$P\left(\left|\frac{X_1 + \cdots + X_n}{n} - m\right| \geq \varepsilon\right) \leq \frac{\sigma^2}{n\varepsilon^2} \xrightarrow[n\to\infty]{} 0.$$

□

7.3 La loi forte des grands nombres

Theorem 7.3.1 (Loi forte des grands nombres)**.** Soit $(X_n)_{n\geq 1}$ une suite de v.a. i.i.d. intégrables, c'est-à-dire $E[|X_1|] < +\infty$. Alors

$$\frac{X_1 + \cdots + X_n}{n} \xrightarrow[n\to\infty]{p.s.} E[X_1].$$

Preuve (Éléments de preuve)**.** La preuve se décompose en plusieurs étapes.

1ère étape : Centrage

Posons $m = E[X_1]$. Quitte à remplacer X_n par $X_n - m$ pour $n \geq 1$, nous pouvons supposer que la suite est centrée, c'est-à-dire que $E[X_i] = 0$ pour tout i.

2ème étape : Troncature

Posons, pour tout $n \geq 1$, $Y_n = X_n \mathbb{I}_{\{|X_n| \leq n\}}$. C'est-à-dire :

$$Y_n = \begin{cases} X_n & \text{si } |X_n| \leq n \\ 0 & \text{sinon} \end{cases}$$

On peut alors décomposer la moyenne de la manière suivante :

$$\frac{X_1 + \cdots + X_n}{n} = \frac{(X_1 - Y_1) + \cdots + (X_n - Y_n)}{n} + \frac{Y_1 + \cdots + Y_n}{n}.$$

La preuve consiste à montrer que les deux termes du membre de droite tendent vers 0 presque sûrement. Pour le premier terme, on utilise le lemme suivant. □

Lemma 7.3.2. Soit $(X_n)_{n\geq 1}$ une suite de v.a. i.i.d. On a équivalence entre :

i) $E[|X_1|] < +\infty$

ii) $P(|X_n| > n \text{ i.s.}) = 0$

Preuve. Comme les événements $\{|X_n| > n\}$ pour $n \geq 1$ ne sont pas indépendants (car la loi est la même), on ne peut pas appliquer directement le second lemme de Borel-Cantelli. Cependant, le premier lemme de Borel-Cantelli s'applique. Les événements $\{|X_n| > n\}$ sont indépendants. Par le lemme de Borel-Cantelli, on a l'équivalence :

$$P(|X_n| > n \text{ i.s.}) = 0 \iff \sum_{n\geq 1} P(|X_n| > n) < +\infty.$$

Comme les variables X_n sont identiquement distribuées, $P(|X_n| > n) = P(|X_1| > n)$, donc l'équivalence devient

$$\sum_{n\geq 1} P(|X_1| > n) < +\infty.$$

Il reste à montrer que $\sum_{n\geq 1} P(|X_1| > n) < +\infty \iff E[|X_1|] < +\infty$. Pour une variable aléatoire positive Z, on a $E[Z] = \int_0^{+\infty} P(Z > t)dt$. Appliquons cela à $Z = |X_1|$:

$$\begin{aligned} E[|X_1|] &= \int_0^{+\infty} P(|X_1| > t)dt \\ &= \sum_{n=0}^{\infty} \int_n^{n+1} P(|X_1| > t)dt. \end{aligned}$$

Pour $t \in [n, n+1)$, on a l'encadrement $P(|X_1| > n+1) \leq P(|X_1| > t) \leq P(|X_1| > n)$. En intégrant sur $[n, n+1]$, on obtient :

$$P(|X_1| > n+1) \leq \int_n^{n+1} P(|X_1| > t)dt \leq P(|X_1| > n).$$

En sommant sur $n \geq 0$:

$$\sum_{n=0}^{\infty} P(|X_1| > n+1) \leq \sum_{n=0}^{\infty} \int_n^{n+1} P(|X_1| > t)dt \leq \sum_{n=0}^{\infty} P(|X_1| > n).$$

Ce qui se réécrit :

$$\sum_{k=1}^{\infty} P(|X_1| > k) \leq E[|X_1|] \leq \sum_{k=0}^{\infty} P(|X_1| > k) = P(|X_1| > 0) + \sum_{k=1}^{\infty} P(|X_1| > k).$$

L'espérance $E[|X_1|]$ est donc finie si et seulement si la série $\sum_{n\geq 1} P(|X_1| > n)$ converge. □

Par le lemme, comme $E[|X_1|] < \infty$, on a $P(|X_n| > n \text{ i.s.}) = 0$, ce qui est équivalent à $P(X_n \neq Y_n \text{ i.s.}) = 0$. Ceci implique que la série $\sum(X_n - Y_n)$ converge presque sûrement. Par le lemme de Kronecker, il s'ensuit que

$$\frac{(X_1 - Y_1) + \cdots + (X_n - Y_n)}{n} \xrightarrow[n\to\infty]{p.s.} 0.$$

La preuve complète de la loi forte des grands nombres requiert alors de montrer que le second terme $\frac{1}{n}\sum_{i=1}^{n} Y_i$ converge également vers 0 p.s., ce qui se fait en utilisant le critère de Kolmogorov.

7.4 Critère de Kolmogorov

Proposition 7.4.1. Soit $(Z_n)_{n\geq 1}$ une suite de v.a. indépendantes et centrées ($E[Z_n] = 0$ pour tout n).

Si $\sum_{n\geq 1} \frac{E[Z_n^2]}{n^2} < +\infty$, alors la série $\sum_{n\geq 1} \frac{Z_n}{n}$ converge p.s. et

$$\frac{Z_1 + \cdots + Z_n}{n} \xrightarrow[n\to\infty]{p.s.} 0.$$

Preuve. La preuve est omise. □

CHAPTER 8

CONVERGENCE EN LOI

La loi, c'est ce qu'il y a de plus important.

8.1 Définition

Il existe des suites de variables aléatoires qui ne convergent ni presque sûrement, ni en probabilité, ni en L^1, mais dont la loi converge, voire est même constante.

Example 8.1.1. Considérons l'espace de probabilité $(\Omega, \mathcal{F}, P) = ([0,1], \mathcal{B}([0,1]), \lambda)$ où λ est la mesure de Lebesgue. Considérons la suite de variables aléatoires (X_n) définies pour $\omega \in [0,1]$ par :

$$X_{2n}(\omega) = \mathbf{1}_{[0,1/2]}(\omega)$$
$$X_{2n+1}(\omega) = \mathbf{1}_{[1/2,1]}(\omega)$$

Cette suite ne converge ni p.s., ni L^1, ni en probabilité, mais toutes les v.a. suivent la loi de Bernoulli de paramètre 1/2.

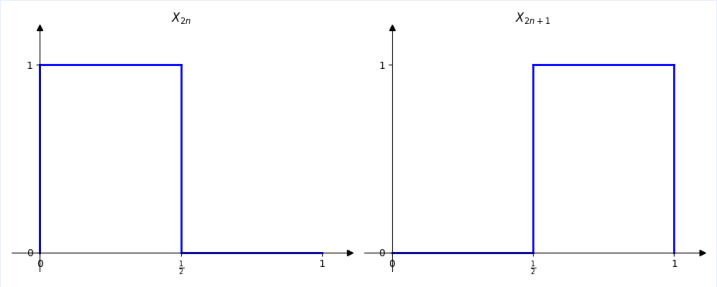

Figure 8.1: Représentation des variables aléatoires X_{2n} et X_{2n+1}.

Pour tout n, la loi de X_n est la loi de Bernoulli(1/2).

$$\forall n, P(X_n = 0) = P(X_n = 1) = \frac{1}{2}$$

et donc $P_{X_n} = \text{Ber}(1/2)$ ne dépend pas de n.

Definition 8.1.2 (Convergence en loi)**.** Soit $(X_n)_{n\in\mathbb{N}}$ une suite de variables aléatoires réelles (qui ne sont pas nécessairement définies sur le même espace de probabilité). La suite $(X_n)_{n\in\mathbb{N}}$ converge en loi vers une variable aléatoire X, ce que l'on note $X_n \xrightarrow{\mathcal{L}} X$, si et seulement si, pour toute fonction continue bornée $f : \mathbb{R} \to \mathbb{R}$,

$$\lim_{n\to\infty} \mathbb{E}[f(X_n)] = \mathbb{E}[f(X)].$$

Remark 8.1.3. L'espérance $\mathbb{E}[f(X_n)]$ ne dépend que de la loi de X_n, i.e.,

$$\mathbb{E}[f(X_n)] = \int_\Omega f(X_n)dP = \int_{\mathbb{R}} f(x)dP_{X_n}(x).$$

Ainsi la convergence en loi s'applique même dans les situations où les v.a. X_n ne sont pas définies sur le même espace de probabilité $(\Omega, \mathcal{F}, P)$, i.e. si $X_n : (\Omega_n, \mathcal{F}_n, P_n) \to (\mathbb{R}, \mathcal{B}(\mathbb{R}))$ où les $(\Omega_n, \mathcal{F}_n, P_n)$ n'ont aucun lien a priori. Ceci distingue fondamentalement la convergence en loi des autres modes de convergence.

8.2 La fonction de répartition

Un outil fondamental pour étudier les lois de probabilité sur $\mathbb{R}$ est la fonction de répartition.

Definition 8.2.1. Soit X une variable aléatoire réelle définie sur $(\Omega, \mathcal{F}, P)$. Sa fonction de répartition est la fonction F_X définie par :

$$\forall x \in \mathbb{R}, \quad F_X(x) = P(X \leq x).$$

On a $F_X(x) = P_X((-\infty, x])$. Comme les intervalles $(-\infty, x]$, $x \in \mathbb{R}$ engendrent les boréliens et forment une famille stable par intersection finie (π-système), par l'unicité du théorème d'extension de $\pi - \lambda$, la loi P_X est déterminée par F_X. Conclusion: la fonction de répartition F_X détermine la loi P_X de X.

Une fonction de répartition F vérifie:

i) F est croissante de $\mathbb{R}$ dans $[0, 1]$.

ii) F est continue à droite en tout point.

iii) $\lim_{x\to-\infty} F(x) = 0$ et $\lim_{x\to+\infty} F(x) = 1$.

Preuve. i) Par croissance de la mesure. Si $x_1 \leq x_2$, alors $(-\infty, x_1] \subseteq (-\infty, x_2]$, donc $P(X \leq x_1) \leq P(X \leq x_2)$.

ii) Soit $x_0 \in \mathbb{R}$. Regardons $\lim_{x\to x_0, x>x_0} F_X(x)$. Soit $(x_n)_{n\in\mathbb{N}}$ une suite qui décroît vers x_0. Alors les ensembles $A_n = (-\infty, x_n]$ forment une suite décroissante d'événements. Par continuité monotone de la probabilité :

$$\lim_{n\to\infty} F_X(x_n) = \lim_{n\to\infty} P(X \in A_n) = P(X \in \bigcap_{n=1}^{\infty} A_n) = P(X \in (-\infty, x_0]) = F_X(x_0).$$

iii) Par continuité monotone de la probabilité. Pour la limite en $-\infty$, on prend une suite $x_n \to -\infty$ (e.g. $x_n = -n$).

$$\lim_{x\to-\infty} F_X(x) = \lim_{n\to\infty} P(X \leq -n) = P(\bigcap_{n=1}^{\infty} \{X \leq -n\}) = P(\emptyset) = 0.$$

Pour la limite en $+\infty$, on prend une suite $x_n \to +\infty$ (e.g. $x_n = n$).

$$\lim_{x\to+\infty} F_X(x) = \lim_{n\to\infty} P(X \le n) = P(\bigcup_{n=1}^{\infty}\{X \le n\}) = P(X \in \mathbb{R}) = 1.$$

□

Remark 8.2.2. Dans certains livres, F_X est définie comme $F_X(x) = P(X < x)$. Dans ce cas, la fonction de répartition est continue à gauche.

Example 8.2.3 (Fonctions de répartition de lois classiques).

1. $X \sim \mathcal{B}(p)$ (loi de Bernoulli). $F_X(x) = 0$ si $x < 0$, $1-p$ si $0 \le x < 1$, et 1 si $x \ge 1$.
2. $X \sim \mathcal{U}(\{1,\dots,n\})$ (loi uniforme discrète). $F_X(x) = \frac{\lfloor x \rfloor}{n}$ pour $1 \le x \le n$.
3. $X \sim \mathcal{U}([0,1])$ (loi uniforme continue). $F_X(x) = 0$ si $x < 0$, x si $0 \le x \le 1$, et 1 si $x > 1$.
4. $X \sim \mathrm{Exp}(\lambda)$ (loi exponentielle). $F_X(x) = 1 - e^{-\lambda x}$ si $x \ge 0$, et 0 si $x < 0$.
5. $X \sim \mathcal{N}(0,1)$ (loi normale centrée réduite). $F_X(x) = \int_{-\infty}^{x} \frac{1}{\sqrt{2\pi}} e^{-t^2/2} dt$.

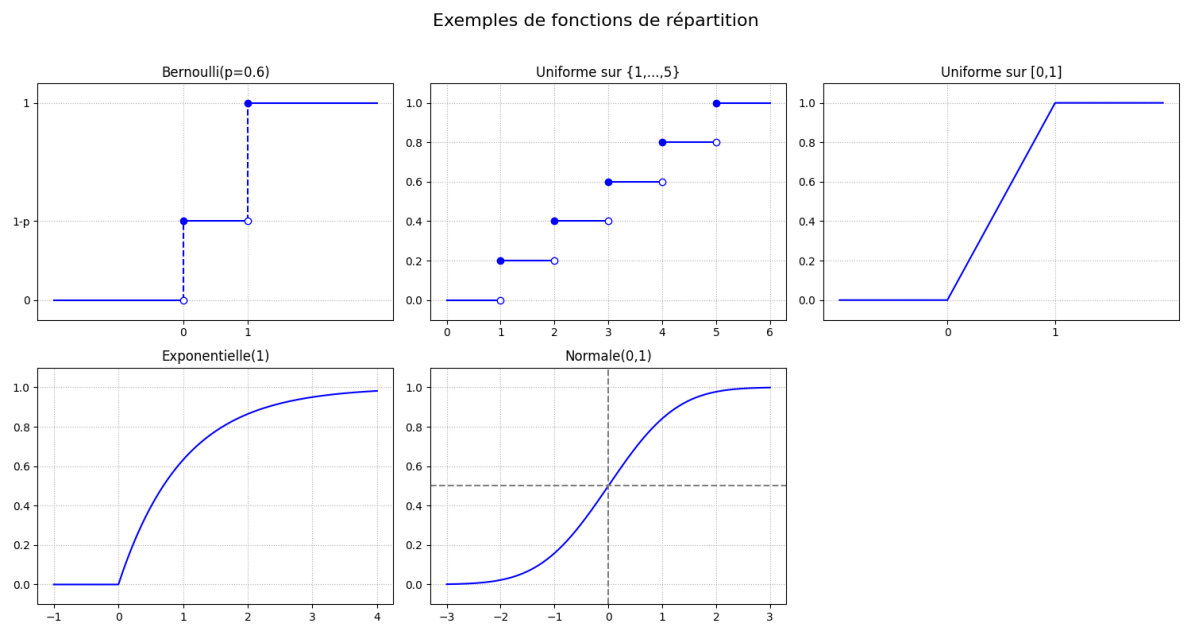

Figure 8.2: Exemples de fonctions de répartition.

Plus généralement, si la loi de X admet une densité f, alors sa fonction de répartition est donnée par

$$F_X(x) = \int_{-\infty}^{x} f(t)dt.$$

Theorem 8.2.4. Notons $\mathcal{M}_1(\mathbb{R})$ l'ensemble des mesures de probabilité sur $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$ et $\mathfrak{R}$ l'ensemble des fonctions qui satisfont les trois propriétés d'une fonction de répartition. L'application $\mu \mapsto F_\mu$, où

$F_\mu(x) = \mu((-\infty, x])$, est une bijection de $\mathcal{M}_1(\mathbb{R})$ dans $\mathfrak{R}$.

Il s'agit d'un résultat difficile, qui permet notamment de construire des mesures de probabilités singulières sur $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$.

Example 8.2.5 (Construction d'une loi singulière)**.** On peut construire une suite de fonctions de répartition (F_n) sur $[0, 1]$ qui converge uniformément vers une fonction continue F_∞, la fonction de Cantor. Cette fonction F_∞ est une fonction de répartition, mais la mesure de probabilité associée μ est singulière par rapport à la mesure de Lebesgue λ. Elle ne possède pas d'atomes ($\mu(\{x\}) = 0$ pour tout x) et est concentrée sur un ensemble de mesure de Lebesgue nulle (l'ensemble de Cantor).

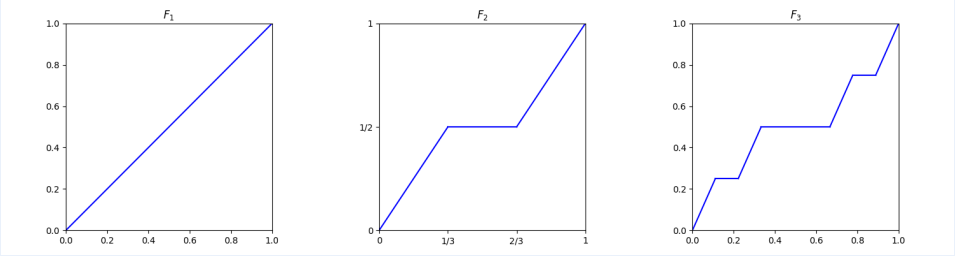

Figure 8.3: Premières étapes de la construction de la fonction de Cantor.

8.3 Convergence en loi et fonctions de répartition

Comme la convergence en loi porte sur les lois de v.a., elle doit pouvoir s'exprimer via les fonctions de répartition.

Theorem 8.3.1. Soit $(X_n)_{n\in\mathbb{N}}$ une suite de variables aléatoires réelles et X une autre v.a. réelle. Notons $(F_n)_{n\in\mathbb{N}}$ et F leurs fonctions de répartition associées. Les affirmations suivantes sont équivalentes :

i) La suite (X_n) converge en loi vers X ($X_n \xrightarrow{\mathcal{L}} X$).

ii) En tout point $x \in \mathbb{R}$ où F est continue, la suite $(F_n(x))$ converge vers $F(x)$, i.e. $\lim_{n\to\infty} F_n(x) = F(x)$.

Preuve. $(i) \Rightarrow (ii)$: Soit x_0 un point où F est continue. Il s'agit de montrer que $\lim_{n\to\infty} F_n(x_0) = F(x_0)$. Pour tout $\epsilon > 0$, on peut construire deux fonctions continues bornées f_ϵ et g_ϵ qui "encadrent" la fonction indicatrice $\mathbf{1}_{(-\infty,x_0]}$ de la manière suivante:

$$f_\epsilon \leq \mathbf{1}_{(-\infty,x_0]} \leq g_\epsilon$$

et telles que $\mathbb{E}[g_\epsilon(X)] - \mathbb{E}[f_\epsilon(X)]$ soit petit. Par exemple, posons f_ϵ égale à 1 sur $(-\infty, x_0 - \epsilon]$, 0 sur $[x_0, \infty)$ et linéaire entre les deux. Posons g_ϵ égale à 1 sur $(-\infty, x_0]$, 0 sur $[x_0 + \epsilon, \infty)$ et linéaire entre les deux.

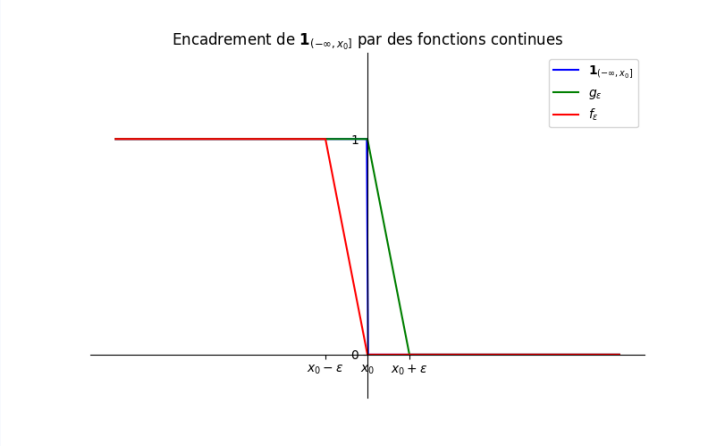

Figure 8.4: Fonctions f_ϵ et g_ϵ encadrant $\mathbf{1}_{(-\infty,x_0]}$.

On a $f_\epsilon(y) \leq \mathbf{1}_{(-\infty,x_0]}(y) \leq g_\epsilon(y)$ pour tout $y \in \mathbb{R}$. En prenant l'espérance par rapport à X_n:

$$\mathbb{E}[f_\epsilon(X_n)] \leq \mathbb{E}[\mathbf{1}_{(-\infty,x_0]}(X_n)] \leq \mathbb{E}[g_\epsilon(X_n)]$$

$$\mathbb{E}[f_\epsilon(X_n)] \leq F_n(x_0) \leq \mathbb{E}[g_\epsilon(X_n)]$$

Puisque f_ϵ et g_ϵ sont continues et bornées, et que $X_n \xrightarrow{\mathcal{L}} X$, on a:

$$\lim_{n\to\infty} \mathbb{E}[f_\epsilon(X_n)] = \mathbb{E}[f_\epsilon(X)]$$
$$\lim_{n\to\infty} \mathbb{E}[g_\epsilon(X_n)] = \mathbb{E}[g_\epsilon(X)]$$

En passant à la limite dans l'inégalité, on obtient:

$$\mathbb{E}[f_\epsilon(X)] \leq \liminf_{n\to\infty} F_n(x_0) \leq \limsup_{n\to\infty} F_n(x_0) \leq \mathbb{E}[g_\epsilon(X)]$$

De plus, $\mathbb{E}[f_\epsilon(X)] \geq P(X \leq x_0 - \epsilon) = F(x_0 - \epsilon)$ et $\mathbb{E}[g_\epsilon(X)] \leq P(X \leq x_0 + \epsilon) = F(x_0 + \epsilon)$. Donc,

$$F(x_0 - \epsilon) \leq \liminf_{n\to\infty} F_n(x_0) \leq \limsup_{n\to\infty} F_n(x_0) \leq F(x_0 + \epsilon)$$

Comme x_0 est un point de continuité de F, on a $\lim_{\epsilon\to 0} F(x_0 - \epsilon) = \lim_{\epsilon\to 0} F(x_0 + \epsilon) = F(x_0)$. En faisant tendre ϵ vers 0, on obtient par le théorème des gendarmes:

$$\lim_{n\to\infty} F_n(x_0) = F(x_0).$$

$(ii) \Rightarrow (i)$: Supposons que $F_{X_n}(x) \to F_X(x)$ en tout point x où F_X est continue. Soit $f : \mathbb{R} \to \mathbb{R}$ une fonction continue et bornée. Il faut montrer que $E[f(X_n)] \to E[f(X)]$. Soit $\epsilon > 0$. Comme $\lim_{x\to-\infty} F_X(x) = 0$ et $\lim_{x\to+\infty} F_X(x) = 1$, il existe $a < b$, points de continuité de F_X, tels que $F_X(a) < \epsilon$ et $F_X(b) > 1 - \epsilon$ (donc $P(X > b) < \epsilon$). On décompose l'espérance :

$$E[f(X_n)] = \int_{x\leq a} f(x)dP_{X_n} + \int_{a<x\leq b} f(x)dP_{X_n} + \int_{x>b} f(x)dP_{X_n}$$

Les intégrales sur les queues sont petites. Pour n assez grand, $F_{X_n}(a) \to F_X(a) < \epsilon$ et $1 - F_{X_n}(b) \to 1 - F_X(b) < \epsilon$.

$$\left| \int_{x \leq a} f(x) dP_{X_n} \right| \leq \|f\|_\infty P(X_n \leq a) = \|f\|_\infty F_{X_n}(a) \xrightarrow{n\to\infty} \|f\|_\infty F_X(a) \leq \epsilon \|f\|_\infty$$
$$\left| \int_{x > b} f(x) dP_{X_n} \right| \leq \|f\|_\infty P(X_n > b) = \|f\|_\infty (1 - F_{X_n}(b)) \xrightarrow{n\to\infty} \|f\|_\infty (1 - F_X(b)) \leq \epsilon \|f\|_\infty$$

Sur l'intervalle $[a, b]$, f est uniformément continue. On peut l'approcher par une fonction en escalier. Soit une subdivision $a = x_0 < x_1 < \cdots < x_k = b$ par des points de continuité de F_X. Définissons la fonction en escalier f_k^+ par :

$$f_k^+(x) = \sum_{l=1}^{k} \mathbf{1}_{]x_{l-1}, x_l]}(x) \sup_{t \in [x_{l-1}, x_l]} f(t)$$

Alors $f(x) \leq f_k^+(x)$ sur $]a, b]$. On a

$$\int_{a<x\leq b} f(x) dP_{X_n} \leq \int_{a<x\leq b} f_k^+(x) dP_{X_n} = \sum_{l=1}^{k} \left(\sup_{t \in [x_{l-1}, x_l]} f(t) \right) (F_{X_n}(x_l) - F_{X_n}(x_{l-1}))$$

En passant à la limite pour $n \to \infty$, comme les x_l sont des points de continuité :

$$\limsup_{n\to\infty} \int_{a<x\leq b} f(x) dP_{X_n} \leq \sum_{l=1}^{k} \left(\sup_{t \in [x_{l-1}, x_l]} f(t) \right) (F_X(x_l) - F_X(x_{l-1})) = E[f_k^+(X) \mathbf{1}_{]a,b]}]$$

Par continuité uniforme de f sur $[a, b]$, quand le pas de la subdivision tend vers 0 ($k \to \infty$), $f_k^+(x) \to f(x)$. Par convergence dominée (car $|f_k^+| \leq \|f\|_\infty$), on a $E[f_k^+(X) \mathbf{1}_{]a,b]}] \to E[f(X) \mathbf{1}_{]a,b]}]$. En combinant les bornes sur les queues et sur l'intervalle central, on obtient pour ϵ arbitrairement petit et n et k assez grands :

$$\limsup_{n\to\infty} E[f(X_n)] \leq E[f(X)]$$

Un raisonnement similaire avec une fonction en escalier minorante f_k^- montre que :

$$\liminf_{n\to\infty} E[f(X_n)] \geq E[f(X)]$$

On en conclut que $\lim_{n\to\infty} E[f(X_n)] = E[f(X)]$. □

CHAPTER 9

LES FONCTIONS CARACTÉRISTIQUES

Si f est une fonction de $\mathbb{R}$ dans $\mathbb{C}$ et μ une mesure sur $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$, nous définissons

$$\int f d\mu = \int \text{Re } f d\mu + i \int \text{Im } f d\mu,$$

lorsque le membre de droite a un sens, c'est-à-dire sous réserve que Re f et Im f sont μ-intégrables.

9.1 Définitions

Definition 9.1.1 (Fonction caractéristique d'une mesure μ)**.** Soit μ une mesure de probabilité sur $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$. Sa fonction caractéristique est

$$\forall u \in \mathbb{R} \quad \varphi_\mu(u) = \int_{\mathbb{R}} e^{iux} d\mu(x).$$

Cette fonction est bien définie pour tout $u \in \mathbb{R}$, car la fonction $x \mapsto e^{iux}$ est continue et bornée, puisque $|e^{iux}| = 1$. Par conséquent, ses parties réelle $(\cos(ux))$ et imaginaire $(\sin(ux))$ sont intégrables par rapport à toute mesure de probabilité.

Definition 9.1.2 (Fonction caractéristique d'une v.a.)**.** Soit X une variable aléatoire réelle définie sur $(\Omega, \mathcal{F}, P)$. Sa fonction caractéristique est

$$\forall u \in \mathbb{R} \quad \varphi_X(u) = E[e^{iux}].$$

Le lien entre les deux définitions est donné par la formule de transfert. L'espérance de e^{iux} est l'intégrale de la fonction $x \mapsto e^{iux}$ par rapport à la loi de probabilité P_X de la variable X.

$$E[e^{iux}] = \int_{\mathbb{R}} e^{iux} dP_X(x).$$

Ainsi, la fonction caractéristique d'une variable aléatoire X est la fonction caractéristique de sa loi P_X.

$$\varphi_X = \varphi_{P_X}.$$

La fonction caractéristique est, à un signe près, la transformée de Fourier de la loi P_X.

9.2 Propriétés

Proposition 9.2.1. Si X est une variable aléatoire réelle, sa fonction caractéristique φ_X vérifie :

i) $\varphi_X(0) = 1$.

ii) $\forall u \in \mathbb{R}, |\varphi_X(u)| \leq 1$.

iii) $\forall u \in \mathbb{R}, \varphi_X(-u) = \overline{\varphi_X(u)}$.

iv) φ_X est continue sur $\mathbb{R}$.

Preuve. i) C'est évident : $\varphi_X(0) = E[e^{i\cdot 0\cdot X}] = E[e^0] = E[1] = 1$.

ii) En utilisant la croissance de l'espérance et le fait que l'espérance d'une constante est cette constante :

$$|\varphi_X(u)| = |E[e^{iux}]| \leq E[|e^{iux}|] = E[1] = 1.$$

iii) Par les propriétés du conjugué complexe et de la linéarité de l'espérance :

$$\overline{\varphi_X(u)} = \overline{E[e^{iux}]} = E[\overline{e^{iux}}] = E[e^{-iux}] = \varphi_X(-u).$$

iv) Pour montrer la continuité, soit $u_0 \in \mathbb{R}$. Nous voulons montrer que $\lim_{u\to u_0} \varphi_X(u) = \varphi_X(u_0)$.

$$\varphi_X(u) = \int_\Omega e^{iux} dP.$$

Il s'agit d'une intégrale dépendant d'un paramètre u. La fonction sous l'intégrale, $g(u,\omega) = e^{iuX(\omega)}$, est continue en u pour tout ω. De plus, nous avons une majoration uniforme :

$$|e^{iux}| \leq 1, \quad \forall u \in \mathbb{R}, \forall x \in \mathbb{R}.$$

La fonction constante 1 est P-intégrable. Par le théorème de convergence dominée, on peut intervertir la limite et l'intégrale :

$$\lim_{u\to u_0} \varphi_X(u) = \lim_{u\to u_0} \int_\Omega e^{iuX} dP = \int_\Omega \lim_{u\to u_0} e^{iuX} dP = \int_\Omega e^{iu_0X} dP = \varphi_X(u_0).$$

Donc φ_X est continue sur $\mathbb{R}$.

□

Proposition 9.2.2 (Effet d'une transformation affine)**.** Soit X une variable aléatoire et $\alpha, \beta \in \mathbb{R}$. La fonction caractéristique de la variable aléatoire $\alpha X + \beta$ est donnée par :

$$\varphi_{\alpha X+\beta}(u) = e^{iu\beta}\varphi_X(\alpha u).$$

Preuve. Le calcul est direct en utilisant les propriétés de l'espérance :

$$\begin{aligned}
\varphi_{\alpha X+\beta}(u) &= E[e^{iu(\alpha X+\beta)}] \\
&= E[e^{iu\alpha X} e^{iu\beta}] \\
&= e^{iu\beta} E[e^{i(u\alpha)X}] \\
&= e^{iu\beta}\varphi_X(\alpha u).
\end{aligned}$$

□

9.3 Exemples classiques

Example 9.3.1 (Loi de Bernoulli)**.** Si $X \sim Ber(p)$, alors $P(X = 1) = p$ et $P(X = 0) = 1 - p$.

$$\varphi_X(u) = E[e^{iux}] = P(X = 0)e^{iu\cdot 0} + P(X = 1)e^{iu\cdot 1} = (1 - p) \cdot 1 + p \cdot e^{iu} = 1 - p + pe^{iu}.$$

Example 9.3.2 (Loi de Poisson)**.** Si $X \sim \mathcal{P}(\theta)$, alors $P(X = k) = e^{-\theta}\frac{\theta^k}{k!}$ pour $k \in \mathbb{N}$.

$$\begin{aligned}
\varphi_X(u) = E[e^{iux}] &= \sum_{k=0}^{+\infty} e^{iuk} P(X = k) \\
&= \sum_{k=0}^{+\infty} e^{iuk} e^{-\theta} \frac{\theta^k}{k!} \\
&= e^{-\theta} \sum_{k=0}^{+\infty} \frac{(\theta e^{iu})^k}{k!} \\
&= e^{-\theta} e^{\theta e^{iu}} = e^{\theta(e^{iu}-1)}.
\end{aligned}$$

Example 9.3.3 (Loi Exponentielle)**.** Si $X \sim \mathcal{E}(\alpha)$, sa densité est $f_X(x) = \alpha e^{-\alpha x}$ pour $x \geq 0$.

$$\begin{aligned}
\varphi_X(u) = E[e^{iux}] &= \int_0^{+\infty} e^{iux} \alpha e^{-\alpha x} dx \\
&= \alpha \int_0^{+\infty} e^{(iu-\alpha)x} dx \\
&= \alpha \left[\frac{e^{(iu-\alpha)x}}{iu - \alpha} \right]_0^{+\infty} \\
&= \alpha \left(0 - \frac{1}{iu - \alpha} \right) = \frac{\alpha}{\alpha - iu}.
\end{aligned}$$

Example 9.3.4 (La loi Gaussienne)**.** Soit X une variable aléatoire de loi normale $\mathcal{N}(m, \sigma^2)$ avec $m \in \mathbb{R}$ et $\sigma > 0$. Posons $Z = \frac{X-m}{\sigma}$. Alors Z suit une loi normale centrée réduite, $Z \sim \mathcal{N}(0, 1)$. Calculons d'abord $\varphi_Z(u)$.

$$\varphi_Z(u) = E[e^{iuZ}] = \int_{-\infty}^{+\infty} e^{iuz} \frac{1}{\sqrt{2\pi}} e^{-z^2/2} dz.$$

L'exposant peut être réécrit en complétant le carré :

$$iuz - \frac{z^2}{2} = -\frac{1}{2}(z^2 - 2iuz) = -\frac{1}{2}((z - iu)^2 - (iu)^2) = -\frac{1}{2}(z - iu)^2 - \frac{u^2}{2}.$$

L'intégrale devient :

$$\varphi_Z(u) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{+\infty} e^{-\frac{1}{2}(z-iu)^2 - \frac{u^2}{2}} dz = e^{-u^2/2} \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{+\infty} e^{-\frac{1}{2}(z-iu)^2} dz.$$

Considérons l'intégrale $I(u) = \int_{-\infty}^{+\infty} e^{-\frac{1}{2}(x-iu)^2} dx$. On peut montrer que cette intégrale ne dépend pas de u. Une méthode consiste à utiliser l'intégration par contour dans le plan complexe.

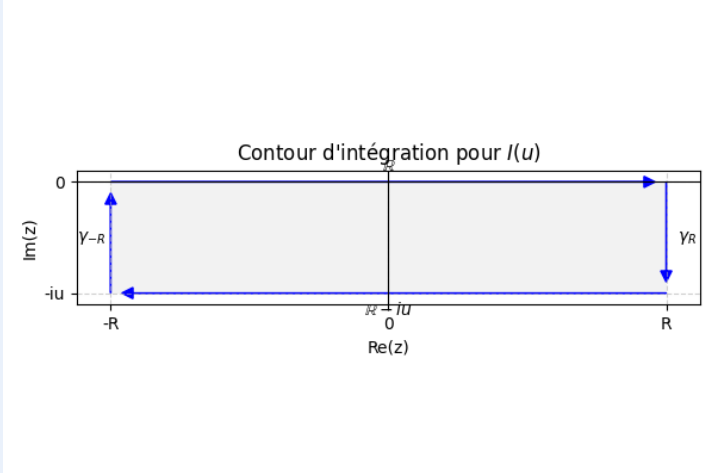

Figure 9.1: Le contour rectangulaire dans le plan complexe utilisé pour montrer que $I(u)$ est constant.

Une autre méthode est de dériver sous le signe intégral. Soit $f(x,u) = e^{-\frac{1}{2}(x-iu)^2}$. On a $\frac{\partial f}{\partial u} = i(x-iu)e^{-\frac{1}{2}(x-iu)^2}$. Cette dérivée partielle est intégrable par rapport à x.

$$\begin{aligned} I'(u) = \int_{\mathbb{R}} \frac{\partial f}{\partial u}(x,u)dx &= \int_{\mathbb{R}} i(x-iu)e^{-\frac{1}{2}(x-iu)^2}dx \\ &= -i\int_{\mathbb{R}} \frac{\partial}{\partial x}\left(e^{-\frac{1}{2}(x-iu)^2}\right)dx \\ &= -i\left[e^{-\frac{1}{2}(x-iu)^2}\right]_{-\infty}^{+\infty} = 0. \end{aligned}$$

Puisque $I'(u) = 0$, $I(u)$ est une constante. On peut l'évaluer en $u = 0$:

$$I(u) = I(0) = \int_{-\infty}^{+\infty} e^{-x^2/2}dx = \sqrt{2\pi}.$$

Ainsi, pour $Z \sim \mathcal{N}(0,1)$,

$$\varphi_Z(u) = e^{-u^2/2}\frac{1}{\sqrt{2\pi}}I(u) = e^{-u^2/2}\frac{\sqrt{2\pi}}{\sqrt{2\pi}} = e^{-u^2/2}.$$

Maintenant, pour $X \sim \mathcal{N}(m,\sigma^2)$, on a $X = \sigma Z + m$. En utilisant la propriété de transformation affine :

$$\varphi_X(u) = \varphi_{\sigma Z+m}(u) = e^{ium}\varphi_Z(\sigma u) = e^{ium}e^{-(\sigma u)^2/2} = e^{ium-\frac{\sigma^2u^2}{2}}.$$

On note que la densité gaussienne est un vecteur propre de la transformée de Fourier. Soit $\psi_\sigma(x) = \frac{1}{\sqrt{2\pi}\sigma}e^{-x^2/(2\sigma^2)}$. On a $\int e^{iux}\psi_\sigma(x)dx = e^{-\sigma^2u^2/2}$. En posant $g_{1/\sigma}(u) = e^{-u^2/(2/\sigma^2)}$, on a $\int e^{iux}\psi_\sigma(x)dx = \psi_{1/\sigma}(u)$.

9.3.1 Récapitulatif

Le tableau suivant résume les fonctions caractéristiques pour plusieurs lois de probabilité classiques.

Loi P_X	$\varphi_X(u)$
Loi de Dirac δ_a	e^{iau}
Loi de Bernoulli $Ber(p)$	$1-p+pe^{iu}$
Loi de Poisson $P(\lambda)$	$\exp(\lambda(e^{iu}-1))$
Loi Géométrique $Geo(p)$	$\frac{pe^{iu}}{1-(1-p)e^{iu}}$
Loi Exponentielle $Exp(\alpha)$	$\frac{\alpha}{\alpha-iu}$
Loi Uniforme $U(a,b)$	$\frac{e^{iub}-e^{iua}}{iu(b-a)}$
Loi Normale $N(m,\sigma^2)$	$\exp\left(ium-\frac{1}{2}\sigma^2u^2\right)$

Table 9.1: Fonctions caractéristiques de lois usuelles.

9.4 Théorème d'injectivité

Theorem 9.4.1. Soit $\mathcal{M}_1(\mathbb{R})$ l'ensemble des mesures de probabilités sur $(\mathbb{R},\mathcal{B}(\mathbb{R}))$. L'application

$$\mu \in \mathcal{M}_1(\mathbb{R}) \mapsto \varphi_\mu$$

est injective.

Ce théorème fondamental signifie que la fonction caractéristique détermine de manière unique la loi de probabilité. Si deux variables aléatoires ont la même fonction caractéristique, elles ont la même loi.

Preuve (Idée de la preuve)**.** L'idée est de montrer que la loi de X est déterminée par la famille des lois de $X+\sigma Y$ pour $\sigma>0$, où $Y\sim\mathcal{N}(0,1)$ est indépendante de X. La loi de $X+\sigma Y$ est une version "régularisée" (convoluée) de la loi de X. Soit $(\Omega,\mathcal{F},P)$ un espace de probabilité sur lequel sont définies deux variables aléatoires indépendantes : $X\sim\mu$ et $Y\sim\mathcal{N}(0,1)$. Pour $\sigma>0$, on étudie la variable $X_\sigma=X+\sigma Y$. La fonction caractéristique de X_σ est :

$$\varphi_{X_\sigma}(t)=E[e^{it(X+\sigma Y)}]=E[e^{itX}]E[e^{it\sigma Y}]=\varphi_X(t)\varphi_{\sigma Y}(t)=\varphi_\mu(t)e^{-\frac{\sigma^2t^2}{2}}.$$

Cette fonction est déterminée par $\varphi_\mu(t)$. Soit $f:\mathbb{R}\to\mathbb{R}$ une fonction continue à support compact. L'espérance $E[f(X+\sigma Y)]$ est donnée par :

$$\begin{aligned}E[f(X+\sigma Y)]&=\iint_{\mathbb{R}^2}f(x+\sigma y)d\mu(x)dP_Y(y)\\&=\iint f(x+z)d\mu(x)g_\sigma(z)dz,\end{aligned}$$

où $g_\sigma(z)$ est la densité de $\sigma Y\sim\mathcal{N}(0,\sigma^2)$. En utilisant la représentation de Fourier inverse pour $f(z)=\frac{1}{2\pi}\int e^{-izt}\hat{f}(t)dt$, où $\hat{f}(t)=\int e^{izt}f(z)dz$ (convention de la transformée de Fourier), on peut montrer que $E[f(X+\sigma Y)]$ est complètement déterminé par φ_μ. Une dérivation plus directe (vue dans les notes) est la suivante:

$$\begin{aligned}E[f(X+\sigma Y)]&=\iint f(x+y')d\mu(x)g_\sigma(y')dy'\\\text{changement de variable } z&=x+y'\\&=\iint f(z)g_\sigma(z-x)d\mu(x)dz\\&=\int f(z)\left(\int g_\sigma(z-x)d\mu(x)\right)dz.\end{aligned}$$

L'intégrale interne est la densité de la loi de $X + \sigma Y$, qui est la convolution de la mesure μ et de la densité gaussienne g_σ. Puisque la transformée de Fourier d'une convolution est le produit des transformées de Fourier, la loi de $X + \sigma Y$ a pour fonction caractéristique $\varphi_\mu(t)e^{-\sigma^2 t^2/2}$. Comme la fonction caractéristique détermine la loi, la loi de $X + \sigma Y$ est uniquement déterminée par φ_μ. Maintenant, faisons tendre $\sigma \to 0$. La variable aléatoire $X + \sigma Y$ converge en probabilité vers X. En effet, pour tout $\epsilon > 0$:

$$P(|(X + \sigma Y) - X| > \epsilon) = P(|\sigma Y| > \epsilon) = P\left(|Y| > \frac{\epsilon}{\sigma}\right).$$

Quand $\sigma \to 0$, $\frac{\epsilon}{\sigma} \to +\infty$. Donc,

$$\lim_{\sigma \to 0} P\left(|Y| > \frac{\epsilon}{\sigma}\right) = P(|Y| = \infty) = 0.$$

On a donc $X + \sigma Y \xrightarrow{P} X$. La convergence en probabilité implique la convergence en loi : $X + \sigma Y \xrightarrow{d} X$. Puisque la loi de $X + \sigma Y$ est déterminée par φ_μ pour tout $\sigma > 0$, sa limite en loi, qui est la loi de X, est également déterminée par φ_μ. Cela prouve l'injectivité. La convergence en loi ($X_n \xrightarrow{d} X$) est équivalente à la convergence des fonctions de répartition $F_{X_n}(x) \to F_X(x)$ pour tout point x où F_X est continue. Ceci peut être montré par les inégalités suivantes. Soit x un point de continuité de F_X. Pour tout $\epsilon > 0$:

$$P(X_n \leq x) \leq P(|X_n - X| \geq \epsilon) + P(X \leq x + \epsilon).$$

En prenant la limite supérieure quand $n \to \infty$, et sachant que $X_n \xrightarrow{P} X$ (ce qui implique $P(|X_n - X| \geq \epsilon) \to 0$), on obtient

$$\limsup_{n \to \infty} F_{X_n}(x) \leq F_X(x + \epsilon).$$

De même,

$$P(X \leq x - \epsilon) \leq P(|X_n - X| \geq \epsilon) + P(X_n \leq x).$$

En prenant la limite inférieure, on obtient

$$F_X(x - \epsilon) \leq \liminf_{n \to \infty} F_{X_n}(x).$$

En combinant les deux, pour un point de continuité x de F_X, on peut faire tendre $\epsilon \to 0$:

$$F_X(x) \leq \liminf_{n \to \infty} F_{X_n}(x) \leq \limsup_{n \to \infty} F_{X_n}(x) \leq F_X(x),$$

ce qui prouve que $\lim_{n \to \infty} F_{X_n}(x) = F_X(x)$. □

CHAPTER 10

THÉORÈME CENTRAL LIMITE

10.1 Le théorème de Paul Lévy

Theorem 10.1.1 (Paul Lévy)**.** Soit $(X_n)_{n\in\mathbb{N}}$ une suite de v.a. réelles et soit X une v.a. réelle. Soit ϕ_{X_n}, ϕ_X leurs fonctions caractéristiques. Nous avons équivalence entre:

i) $X_n \xrightarrow{\mathcal{L}} X$

ii) $\forall u \in \mathbb{R}, \lim_{n\to\infty} \phi_{X_n}(u) = \phi_X(u)$

Preuve. Sens facile : i) $\implies$ ii)
On a $\phi_{X_n}(u) = \mathbb{E}[e^{iuX_n}] = \mathbb{E}[\cos(uX_n)] + i\mathbb{E}[\sin(uX_n)]$. Les fonctions $x \mapsto \cos(ux)$ et $x \mapsto \sin(ux)$ (u étant fixé) sont continues et bornées. Par définition de la convergence en loi,

$$\mathbb{E}[\cos(uX_n)] \xrightarrow[n\to\infty]{} \mathbb{E}[\cos(uX)]$$
$$\mathbb{E}[\sin(uX_n)] \xrightarrow[n\to\infty]{} \mathbb{E}[\sin(uX)]$$

et donc $\phi_{X_n}(u) \xrightarrow[n\to\infty]{} \phi_X(u)$. Sens réciproque : ii) $\implies$ i)

Nous utilisons la même stratégie que pour prouver l'injectivité de la transformée de Fourier des mesures de probabilités. Nous supposons que X, X_n pour $n \in \mathbb{N}$ sont toutes définies sur un même espace de probas $(\Omega, \mathcal{F}, P)$, sur lequel est aussi définie une v.a. Y indépendante de X, X_n pour $n \in \mathbb{N}$, et de la loi $\mathcal{N}(0,1)$. Soit $f : \mathbb{R} \to \mathbb{R}$ une fonction continue à support compact. Nous supposons ii) vrai, et nous voulons montrer que $X_n \xrightarrow{\mathcal{L}} X$. Soit $\sigma > 0$ et écrivons :

$$\begin{aligned}\mathbb{E}[f(X_n)] - \mathbb{E}[f(X)] = \mathbb{E}[f(X_n) - f(X_n + \sigma Y)] + \mathbb{E}[f(X_n + \sigma Y)] - \mathbb{E}[f(X + \sigma Y)] \\ + \mathbb{E}[f(X + \sigma Y) - f(X)]\end{aligned}$$

Comme f est continue à support compact, elle est uniformément continue.

$$\forall \varepsilon > 0, \exists \delta > 0, \forall x, y \in \mathbb{R}, |x - y| < \delta \implies |f(x) - f(y)| < \varepsilon$$

Soit $\varepsilon > 0$ fixé. Soit δ associé à ε comme ci-dessus. Écrivons :

$$\begin{aligned}|\mathbb{E}[f(X_n) - f(X_n + \sigma Y)]| &\leq \mathbb{E}[|f(X_n) - f(X_n + \sigma Y)|] \\ &= \int_{|\sigma Y| \leq \delta} |f(X_n) - f(X_n + \sigma Y)| dP + \int_{|\sigma Y| > \delta} |f(X_n) - f(X_n + \sigma Y)| dP\end{aligned}$$

$$\int_{|\sigma Y| \leq \delta} |f(X_n) - f(X_n + \sigma Y)| dP < \varepsilon$$

$$\int_{|\sigma Y| > \delta} |f(X_n) - f(X_n + \sigma Y)| dP \leq \int_{|\sigma Y| > \delta} 2\|f\|_\infty dP = 2\|f\|_\infty \mathbb{P}(|\sigma Y| > \delta)$$

On a $\lim_{\sigma \to 0} \mathbb{P}(|\sigma Y| > \delta) = \lim_{\sigma \to 0} \mathbb{P}(|Y| > \delta/\sigma) = 0$. Donc $\exists \sigma_0$ tel que pour $\sigma < \sigma_0$, $2\|f\|_\infty \mathbb{P}(|\sigma Y| > \delta) < \varepsilon$. On a donc $|\mathbb{E}[f(X_n) - f(X_n + \sigma Y)]| < 2\varepsilon$. Par le même argument, on a $|\mathbb{E}[f(X + \sigma Y) - f(X)]| < 2\varepsilon$. Reste le terme du milieu.

$$\forall n \in \mathbb{N}, \quad |\mathbb{E}[f(X_n)] - \mathbb{E}[f(X)]| \leq 2\varepsilon + |\mathbb{E}[f(X_n + \sigma Y) - f(X + \sigma Y)]| + 2\varepsilon$$

Nous utilisons la formule du cours précédent (via la convolution avec une Gaussienne) :

$$\mathbb{E}[f(X_n + \sigma Y)] = \iint f(z) e^{iuz} \frac{1}{\sqrt{2\pi}\sigma} g_{1/\sigma}(u) \phi_{X_n}(-u) du dz$$

$$\mathbb{E}[f(X + \sigma Y)] = \iint f(z) e^{iuz} \frac{1}{\sqrt{2\pi}\sigma} g_{1/\sigma}(u) \phi_X(-u) du dz$$

où $g_{1/\sigma}$ est la densité de $\mathcal{N}(0, 1/\sigma^2)$. Posons $F_n(u, z) = f(z) e^{iuz} \frac{1}{\sqrt{2\pi}\sigma} g_{1/\sigma}(u) \phi_{X_n}(-u)$. On a :

$$|F_n(u, z)| \leq |f(z)| \frac{1}{\sqrt{2\pi}\sigma} g_{1/\sigma}(u)$$

Cette majoration ne dépend pas de n et est dans $L^1(d\lambda(u), d\lambda(z)) = L^1(\mathbb{R}^2, \lambda^{\otimes 2})$. Par le théorème de convergence dominée (TCD), comme $\phi_{X_n}(u) \to \phi_X(u)$, on a :

$$\exists N, \forall n \geq N, \quad |\mathbb{E}[f(X_n + \sigma Y)] - \mathbb{E}[f(X + \sigma Y)]| < \varepsilon$$

Alors, pour $n \geq N$,

$$|\mathbb{E}[f(X_n)] - \mathbb{E}[f(X)]| < 2\varepsilon + \varepsilon + 2\varepsilon = 5\varepsilon$$

Ceci étant vrai pour tout $\varepsilon > 0$, on a $\mathbb{E}[f(X_n)] \to \mathbb{E}[f(X)]$ pour toute fonction f continue à support compact, ce qui est la définition de la convergence en loi. □

10.2 Moments

Proposition 10.2.1. Soit X une v.a. réelle. Soit $k \geq 1$. Supposons que $\mathbb{E}[|X|^k] < \infty$. Alors ϕ_X est k fois dérivable, et de plus

$$\phi_X^{(k)}(0) = i^k \mathbb{E}[X^k]$$

Preuve. Faisons la preuve pour $k = 1$. On a $\mathbb{E}[|X|] < \infty$. La fonction caractéristique est $\phi_X(u) = \int_{\mathbb{R}} e^{iux} dP_X(x)$. Il s'agit d'une intégrale à paramètre, et on veut dériver par rapport à u. Posons $F(x, u) = e^{iux}$. On a $\frac{\partial F}{\partial u}(x, u) = ixe^{iux}$. On a $\left|\frac{\partial F}{\partial u}(x, u)\right| = |ixe^{iux}| = |x|$. La fonction majorante $|x|$ est P_X-intégrable car $\mathbb{E}[|X|] < \infty$, et elle ne dépend pas de u. Par le théorème de dérivation sous le

signe intégral, ϕ_X est dérivable et

$$\phi'_X(u) = \int_{\mathbb{R}} \frac{\partial F}{\partial u}(x,u)dP_X(x) = \int_{\mathbb{R}} ixe^{iux}dP_X(x)$$

D'où $\phi'_X(0) = \int_{\mathbb{R}} ixdP_X(x) = i\mathbb{E}[X]$. Le résultat pour $k > 1$ s'obtient par récurrence. □

Ce résultat permet de trouver facilement la suite des moments.

Exemples

Example 10.2.2 (Loi uniforme)**.** Soit $X \sim \mathcal{U}([-1,1])$. La densité est $f(x) = \frac{1}{2}\mathbf{1}_{[-1,1]}(x)$.

$$\phi_X(u) = \int_{-1}^{1} e^{iux}\frac{1}{2}dx = \frac{1}{2}\left[\frac{e^{iux}}{iu}\right]_{-1}^{1} = \frac{e^{iu}-e^{-iu}}{2iu} = \frac{\sin(u)}{u}$$

On connaît le développement en série de $\sin(u) = \sum_{n=0}^{\infty}(-1)^n\frac{u^{2n+1}}{(2n+1)!}$. D'où $\phi_X(u) = \frac{\sin(u)}{u} = \sum_{n=0}^{\infty}(-1)^n\frac{u^{2n}}{(2n+1)!}$. La dérivée d'ordre $2n$ en 0 est $(2n)!$ fois le coefficient de u^{2n}:

$$\phi_X^{(2n)}(0) = (2n)!\frac{(-1)^n}{(2n+1)!}$$

D'où, $\mathbb{E}[X^{2n}] = \frac{\phi_X^{(2n)}(0)}{i^{2n}} = \frac{1}{(-1)^n}(2n)!\frac{(-1)^n}{(2n+1)!} = \frac{1}{2n+1}$. Plus facile: $\mathbb{E}[X^{2n}] = \int_{-1}^{1} x^{2n}\frac{1}{2}dx = \frac{1}{2}\left[\frac{x^{2n+1}}{2n+1}\right]_{-1}^{1} = \frac{1}{2n+1}$.

Example 10.2.3 (Loi Gaussienne)**.** Soit $X \sim \mathcal{N}(0,1)$. On sait que $\phi_X(u) = e^{-u^2/2}$. Le développement en série est :

$$\phi_X(u) = e^{-u^2/2} = \sum_{n=0}^{\infty}\frac{1}{n!}\left(-\frac{u^2}{2}\right)^n = \sum_{n=0}^{\infty}\frac{(-1)^n}{n!2^n}u^{2n}$$

On en déduit que $\phi_X^{(2n)}(0) = (2n)!\frac{(-1)^n}{n!2^n}$. D'où $\mathbb{E}[X^{2n}] = \frac{\phi_X^{(2n)}(0)}{i^{2n}} = \frac{1}{(-1)^n}\frac{(2n)!(-1)^n}{n!2^n} = \frac{(2n)!}{n!2^n}$.

10.3 Convolution

Lemma 10.3.1. Soient X, Y deux v.a. indépendantes. Alors $\forall u \in \mathbb{R}$,

$$\phi_{X+Y}(u) = \phi_X(u)\phi_Y(u)$$

Preuve. $\phi_{X+Y}(u) = \mathbb{E}[e^{iu(X+Y)}] = \mathbb{E}[e^{iuX}e^{iuY}]$. Par indépendance de X et Y, les v.a. e^{iuX} et e^{iuY} sont aussi indépendantes. Donc,

$$\mathbb{E}[e^{iuX}e^{iuY}] = \mathbb{E}[e^{iuX}]\mathbb{E}[e^{iuY}] = \phi_X(u)\phi_Y(u)$$

□

Corollary 10.3.2. Si $X_1, \ldots, X_n$ sont n v.a. indépendantes, alors $\phi_{X_1+\cdots+X_n}(u) = \prod_{i=1}^{n}\phi_{X_i}(u)$. Si de plus elles sont identiquement distribuées, $\phi_{X_1+\cdots+X_n}(u) = (\phi_{X_1}(u))^n$.

Supposons que X a une loi de densité f et Y une loi de densité g, et X, Y indépendantes.

$$\phi_{X+Y}(u) = \iint_{\mathbb{R}^2} e^{iu(x+y)} f(x)g(y)dxdy$$

On pose $z = x + y$. On garde x et on remplace $y = z - x$.

$$\begin{aligned}\phi_{X+Y}(u) &= \iint e^{iuz} f(x)g(z-x)dxdz \quad \text{(Fubini)} \\ &= \int e^{iuz} \left(\int f(x)g(z-x)dx \right) dz = \int e^{iuz} h(z)dz\end{aligned}$$

où $h(z) = \int f(x)g(z-x)dx = (f * g)(z)$ est le produit de convolution de f et g. Par identification de ces deux formules, on voit que $X + Y$ a une loi de densité $f * g$. Dès que f et g sont dans L^1, le produit de convolution $f * g$ est bien défini et aussi dans L^1.

10.4 Théorème Central Limite

Theorem 10.4.1 (Théorème Central Limite)**.** Soit $(X_n)_{n\geq 1}$ une suite de v.a. i.i.d. (indépendantes et identiquement distribuées) qui admet un moment d'ordre 2. Posons $m = \mathbb{E}[X_i]$ et $\sigma^2 = \mathrm{Var}[X_i]$. Alors,

$$\frac{X_1 + \cdots + X_n - nm}{\sqrt{n}} \xrightarrow[n\to\infty]{\mathcal{L}} \mathcal{N}(0, \sigma^2)$$

Attention : Il faut absolument centrer les v.a. en soustrayant $\mathbb{E}[X_1 + \cdots + X_n] = nm$.
Par contre, on peut normaliser pour obtenir une variance de 1 :

$$\frac{X_1 + \cdots + X_n - nm}{\sqrt{n}\sigma} \xrightarrow[n\to\infty]{\mathcal{L}} \mathcal{N}(0, 1)$$

Histoire

Il s'agit d'un résultat universel. Dès que les v.a. (X_n) ont un moment d'ordre 2, les fluctuations de $X_1, \ldots, X_n$ autour de sa moyenne sont décrites par la loi gaussienne. Le TLC (ou TCL) est un raffinement de la loi des grands nombres, sous l'hypothèse d'existence d'un moment d'ordre 2.

- **Abraham de Moivre (1733)** : *The doctrine of chances.*
- **Pierre Simon de Laplace (1812)** : *Traité de Mécanique céleste* et *Théorie analytique des probabilités* (CLT pour la loi binomiale, théorème de Moivre-Laplace).
- **Lindeberg**, **Turing (1934)**.

Preuve (Preuve du TCL)**.** On pose $Y_n = \frac{X_1+\cdots+X_n-nm}{\sqrt{n}}$ et $\tilde{X}_k = X_k - m$ pour $1 \leq k \leq n$. On a $\mathbb{E}[\tilde{X}_k] = 0$ et $\mathbb{E}[\tilde{X}_k^2] = \sigma^2$. On peut réécrire $Y_n = \frac{1}{\sqrt{n}} \sum_{k=1}^n \tilde{X}_k$. Étudions la convergence en loi de Y_n à l'aide des fonctions caractéristiques. Les $\tilde{X}_k$ sont i.i.d.

$$\begin{aligned}\phi_{Y_n}(u) = \mathbb{E}\left[e^{iuY_n}\right] = \mathbb{E}\left[e^{i\frac{u}{\sqrt{n}}\sum_{k=1}^n \tilde{X}_k}\right] &= \mathbb{E}\left[\prod_{k=1}^n e^{i\frac{u}{\sqrt{n}}\tilde{X}_k}\right] \\ &= \prod_{k=1}^n \mathbb{E}\left[e^{i\frac{u}{\sqrt{n}}\tilde{X}_k}\right] \quad \text{(par indépendance)} \\ &= \left(\phi_{\tilde{X}_1}\left(\frac{u}{\sqrt{n}}\right)\right)^n \quad \text{(car i.i.d.)}\end{aligned}$$

Comme $\mathbb{E}[\tilde{X}_1^2] < \infty$, $\phi_{\tilde{X}_1}$ est deux fois dérivable. Elle admet donc un développement limité à l'ordre 2 en 0 :

$$\phi_{\tilde{X}_1}(v) = \phi_{\tilde{X}_1}(0) + v\phi'_{\tilde{X}_1}(0) + \frac{v^2}{2}\phi''_{\tilde{X}_1}(0) + o(v^2)$$

Calculons les coefficients:

- $\phi_{\tilde{X}_1}(0) = \mathbb{E}[e^0] = 1$
- $\phi'_{\tilde{X}_1}(0) = i\mathbb{E}[\tilde{X}_1] = i \cdot 0 = 0$
- $\phi''_{\tilde{X}_1}(0) = i^2\mathbb{E}[\tilde{X}_1^2] = -\sigma^2$

Donc, $\phi_{\tilde{X}_1}(v) = 1 - \frac{\sigma^2 v^2}{2} + o(v^2)$. Appliquons ce développement avec $v = u/\sqrt{n}$:

$$\phi_{\tilde{X}_1}\left(\frac{u}{\sqrt{n}}\right) = 1 - \frac{\sigma^2}{2}\left(\frac{u}{\sqrt{n}}\right)^2 + o\left(\left(\frac{u}{\sqrt{n}}\right)^2\right) = 1 - \frac{\sigma^2 u^2}{2n} + o\left(\frac{1}{n}\right)$$

Maintenant, on élève à la puissance n:

$$\phi_{Y_n}(u) = \left(1 - \frac{\sigma^2 u^2}{2n} + o\left(\frac{1}{n}\right)\right)^n$$

Pour trouver la limite, on utilise le logarithme (complexe). On sait que pour $z \to 0$, $\ln(1+z) = z + O(z^2)$.

$$\begin{aligned}
\ln(\phi_{Y_n}(u)) &= n \ln\left(1 - \frac{\sigma^2 u^2}{2n} + o\left(\frac{1}{n}\right)\right) \\
&= n\left(-\frac{\sigma^2 u^2}{2n} + o\left(\frac{1}{n}\right)\right) \\
&= -\frac{\sigma^2 u^2}{2} + n \cdot o\left(\frac{1}{n}\right) = -\frac{\sigma^2 u^2}{2} + o(1)
\end{aligned}$$

Ainsi, $\lim_{n\to\infty} \ln(\phi_{Y_n}(u)) = -\frac{\sigma^2 u^2}{2}$. Par continuité de l'exponentielle,

$$\lim_{n\to\infty} \phi_{Y_n}(u) = e^{-\frac{\sigma^2 u^2}{2}}$$

On reconnaît la fonction caractéristique de la loi $\mathcal{N}(0, \sigma^2)$. On conclut par le théorème de Paul Lévy que $Y_n \xrightarrow{\mathcal{L}} \mathcal{N}(0, \sigma^2)$. $\square$

CHAPTER 11

PROCESSUS DE POISSON

11.1 Introduction et Motivation

Nous voulons modéliser des événements qui arrivent à des dates précises mais imprévisibles.

> **Example 11.1.1.** Exemples de tels événements incluent les séismes, la désintégration d'atomes, la pluie, ou le début et la fin d'appels téléphoniques.

À chaque occurrence d'un événement, nous marquons un impact sur l'axe des temps.

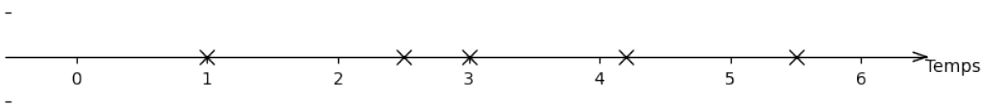

11.2 Hypothèses du modèle

Pour construire notre modèle, nous posons les hypothèses suivantes :

i) Les conditions de l'expérience ne changent pas au cours du temps.

ii) Les nombres d'impacts dans des intervalles de temps disjoints sont indépendants.

Pour $t \geq 0$, nous notons $N(t)$ le nombre d'impacts dans l'intervalle $[0, t]$. Nous avons ainsi une famille de variables aléatoires $(N(t))_{t\geq 0}$ indexée par un paramètre continu. C'est un **processus stochastique**.

11.3 Construction d'un modèle discret

Soit $n \geq 1$ un entier. Nous subdivisons l'axe réel en intervalles de longueur $\frac{1}{n}$, de la forme $\left[\frac{k}{n}, \frac{k+1}{n}\right[$, pour $k \geq 0$.

Un intervalle peut avoir $0, 1, 2, \ldots$ impacts.

Definition 11.3.1. Un intervalle $\left[\frac{k}{n}, \frac{k+1}{n}\right[$ est dit **occupé** s'il contient au moins un impact, et **vide** sinon.

Notons p_n la probabilité qu'un intervalle $\left[\frac{k}{n}, \frac{k+1}{n}\right[$ soit occupé.
D'après l'hypothèse (i), p_n ne dépend pas de l'intervalle.
Pour $t > 0$, notons $N_n(t)$ le nombre d'intervalles $\left[\frac{k}{n}, \frac{k+1}{n}\right[$ (avec $\frac{k+1}{n} \leq t$) qui sont occupés.
Par l'hypothèse (ii), les états (vides ou occupés) de ces intervalles sont indépendants, et $N_n(t)$ suit la loi binomiale $B(\lfloor nt \rfloor, p_n)$.

11.4 Convergence vers la loi de Poisson

Nous étudions la limite en loi de $N_n(t)$, par exemple à l'aide des fonctions caractéristiques. La fonction caractéristique de $N_n(t)$ est :

$$\varphi_{N_n(t)}(u) = E[e^{iuN_n(t)}] = (1 - p_n + p_n e^{iu})^{\lfloor nt \rfloor}$$

Nous ajoutons une hypothèse supplémentaire : $p_n \to 0$ quand $n \to \infty$. Sinon, le modèle "explose". Pour étudier la limite, nous analysons le logarithme de la fonction caractéristique :

$$\begin{aligned} \ln(\varphi_{N_n(t)}(u)) &= \lfloor nt \rfloor \ln(1 - p_n + p_n e^{iu}) \\ &= \lfloor nt \rfloor \ln(1 + p_n(e^{iu} - 1)) \end{aligned}$$

En utilisant le développement limité $\ln(1 + x) = x + o(x)$ pour $x \to 0$, on obtient :

$$\begin{aligned} \ln(\varphi_{N_n(t)}(u)) &= \lfloor nt \rfloor \big(p_n(e^{iu} - 1) + o(p_n)\big) \\ &= \lfloor nt \rfloor p_n(e^{iu} - 1) + o(np_n) \end{aligned}$$

En passant à l'exponentielle :

$$\varphi_{N_n(t)}(u) = e^{\lfloor nt \rfloor p_n(e^{iu} - 1) + o(np_n)}$$

Supposons que $np_n \to \lambda$ lorsque $n \to \infty$, où λ est une constante positive. Alors $\lfloor nt \rfloor p_n \approx ntp_n \to \lambda t$. La limite de la fonction caractéristique devient :

$$\lim_{n \to \infty} \varphi_{N_n(t)}(u) = e^{\lambda t(e^{iu} - 1)}$$

On reconnaît la fonction caractéristique d'une loi de Poisson de paramètre λt. Donc, $N_n(t)$ converge en loi vers une variable aléatoire suivant une loi de Poisson $\mathcal{P}(\lambda t)$.

$$N_n(t) \xrightarrow{\mathcal{L}} \mathcal{P}(\lambda t)$$

Remark 11.4.1 (Rappel sur la loi de Poisson). Une variable aléatoire X à valeurs dans $\mathbb{N}$ suit une loi de Poisson de paramètre $\lambda > 0$, notée $X \sim \mathcal{P}(\lambda)$, si pour tout $k \in \mathbb{N}$:

$$P(X = k) = e^{-\lambda} \frac{\lambda^k}{k!}$$

Son **espérance** et sa **variance** sont égales à λ, i.e., $E[X] = \mathrm{Var}[X] = \lambda$.
Sa **fonction caractéristique** est $\varphi_X(u) = \exp(\lambda(e^{iu} - 1))$.

11.5 Instants de Saut

Nous avons montré que, à t fixé, $N_n(t) \xrightarrow{\mathcal{L}} \mathcal{P}(\lambda t)$. Cependant, la fonction $t \mapsto N_n(t)$ est une **fonction aléatoire** en escalier, nulle en 0, croissante, et dont les accroissements sont soit 0, soit 1.

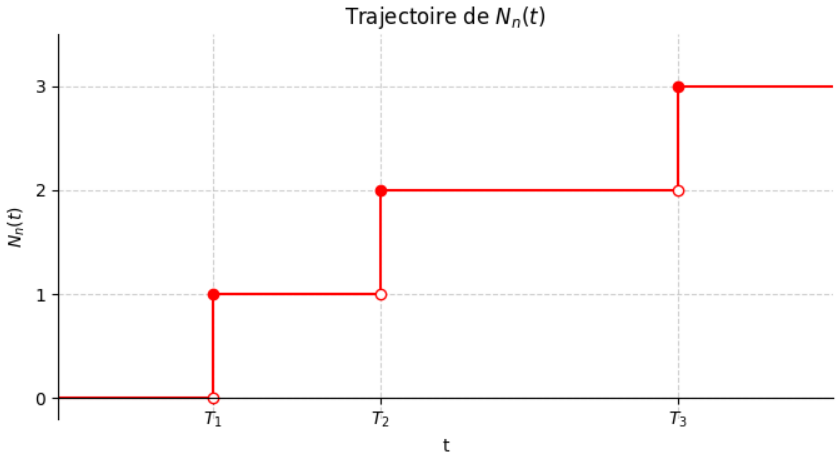

Figure 11.1: Une réalisation de la fonction aléatoire $t \mapsto N_n(t)$.

La question se pose : la fonction aléatoire $t \mapsto N_n(t)$ converge-t-elle quand $n \to \infty$? La fonction $N_n(t)$ est complètement déterminée par ses instants de saut. Nous définissons les instants de saut de $N_n(t)$ par :

$$\forall k \geq 1, \quad T_k^n = \inf\{t \geq 0 : N_n(t) = k\}$$

En effet, on a $N_n(t) = \sum_{k=1}^{\infty} 1_{\{T_k^n \leq t\}}$. Examinons la convergence de ces instants de saut, en commençant par T_1^n. Soit $i \geq 0$ un entier. L'événement $\{T_1^n > i/n\}$ signifie que les i premiers intervalles de temps, $[0, 1/n), [1/n, 2/n), \ldots, [(i-1)/n, i/n)$, sont tous vides. Pour analyser cela, nous introduisons une suite de variables aléatoires X_k pour $k \geq 0$:

$$X_k = \begin{cases} 0 & \text{si l'intervalle } [k/n, (k+1)/n[\text{ est vide} \\ 1 & \text{sinon (occupé)} \end{cases}$$

Alors $P(T_1^n > i/n) = P(X_0 = 0, \ldots, X_{i-1} = 0)$. Par indépendance, ceci vaut $(1 - p_n)^i$. Pour $t > 0$ fixé, choisissons $i = \lfloor nt \rfloor$. Alors :

$$P(T_1^n > t) \approx P(T_1^n > \lfloor nt \rfloor / n) = (1 - p_n)^{\lfloor nt \rfloor}$$

Comme nous avons supposé $np_n \to \lambda$, on a $p_n \approx \lambda/n$.

$$P(T_1^n > t) \approx \left(1 - \frac{\lambda}{n}\right)^{nt} \xrightarrow[n \to \infty]{} e^{-\lambda t}$$

On reconnaît la fonction de survie d'une loi exponentielle. Ainsi, $T_1^n \xrightarrow{\mathcal{L}} \text{Exp}(\lambda)$.

Remark 11.5.1 (Rappel sur la loi Exponentielle). Une variable aléatoire X suit la loi exponentielle de paramètre $\lambda > 0$, notée $\text{Exp}(\lambda)$, si sa loi est de densité $f(x) = \lambda e^{-\lambda x}$ pour $x \geq 0$. Son espérance est $E[X] = 1/\lambda$ et sa variance est $\text{Var}[X] = 1/\lambda^2$. Sa fonction de répartition est $F_X(x) = P(X \leq x) = 1 - e^{-\lambda x}$ pour $x \geq 0$.

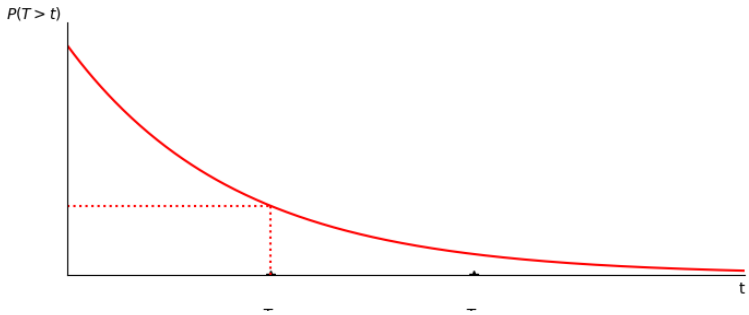

Figure 11.2: Fonction de survie de la loi exponentielle.

On peut montrer de plus que les durées entre les sauts successifs sont indépendantes et de même loi. Par exemple, $T_2^n - T_1^n$ est indépendant de T_1^n et converge aussi en loi vers $\text{Exp}(\lambda)$. Vérifions-le pour le modèle discret.

Remark 11.5.2. Soient $i, j \geq 1$.

$$P(T_1^n = i/n, T_2^n - T_1^n = j/n) = P(X_0 = 0, \ldots, X_{i-1} = 0, X_i = 1, X_{i+1} = 0, \ldots, X_{i+j-1} = 0, X_{i+j} = 1)$$

. Cette probabilité vaut $(1-p_n)^{i-1}p_n \cdot (1-p_n)^{j-1}p_n$. Ceci est égal à $P(T_1^n = i/n) \cdot P(T_1^n = j/n)$. D'où le résultat.
Ainsi, le vecteur des inter-sauts converge en loi :

$$(T_1^n, T_2^n - T_1^n, \ldots, T_k^n - T_{k-1}^n) \xrightarrow[n\to\infty]{\mathcal{L}} (\text{Exp}(\lambda))^{\otimes k}$$

c'est-à-dire vers un vecteur de k variables aléatoires indépendantes et de même loi $\text{Exp}(\lambda)$.

11.6 Le Processus de Poisson Continu

Les calculs précédents nous permettent d'imaginer le candidat pour la limite en loi de $N_n(t)$.

11.6.1 Définition à partir des instants de saut

Soit $(Y_n)_{n\geq 1}$ une suite de variables aléatoires indépendantes et identiquement distribuées suivant la loi exponentielle $\text{Exp}(\lambda)$. Posons $S_0 = 0$ et pour $n \geq 1$, $S_n = Y_1 + Y_2 + \cdots + Y_n$. La variable S_n représente le temps du n-ième événement.

Definition 11.6.1 (Processus de Poisson)**.** Pour tout $t \geq 0$, on définit le nombre d'événements jusqu'à l'instant t par :

$$N(t) = \max\{n \geq 0 : S_n \leq t\}$$

Le processus stochastique $(N(t))_{t\geq 0}$ est appelé le **processus de Poisson** d'intensité λ.

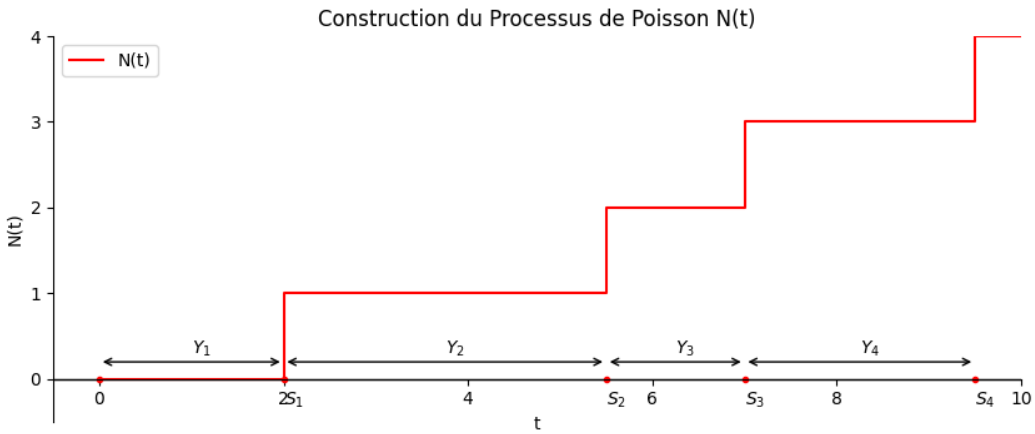

Pour chaque t, $N(t)$ est une variable aléatoire qui suit une loi de Poisson $\mathcal{P}(\lambda t)$. Nous avons ainsi construit un continuum de variables aléatoires $(N(t))_{t\geq 0}$ sur le même espace de probabilités. On a $S_n \to +\infty$ presque sûrement. $N(t)$ est l'unique indice k tel que $S_k \leq t < S_{k+1}$.

11.7 Applications

11.7.1 Application 1 : Bombardements de Londres (WWII)

Pendant la Seconde Guerre mondiale, la ville de Londres a subi 537 impacts de bombes. La carte de la ville a été divisée en un quadrillage de 576 carrés de 0,25 km^2 chacun. Le nombre moyen d'impacts par carré est donc $\lambda = 537/576 \approx 0.9323$. On compare le nombre de carrés ayant reçu k impacts avec les prédictions de la loi de Poisson $\mathcal{P}(0.9323)$.

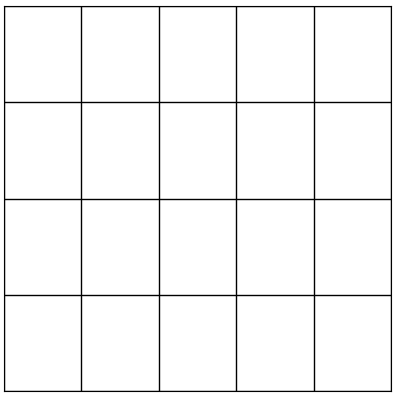

Figure 11.3: Quadrillage de la carte de Londres.

Le tableau suivant compare les données observées (nombre de carrés avec k impacts) et les valeurs attendues selon la loi de Poisson ($576 \times P(X = k)$ avec $X \sim \mathcal{P}(0.9323)$).

k (impacts)	**0**	**1**	**2**	**3**	**4**	≥ 5
Observé	229	211	93	35	7	1
Attendu	226.74	211.39	98.54	30.62	7.14	1.57

11.7.2 Application 2 : Problème d'Autobus

Les arrivées de bus à un arrêt sont modélisées par un processus de Poisson d'intensité λ. Le temps moyen entre deux arrivées est donc $1/\lambda$. J'arrive à l'instant t. Quel sera mon temps d'attente ?

-

-

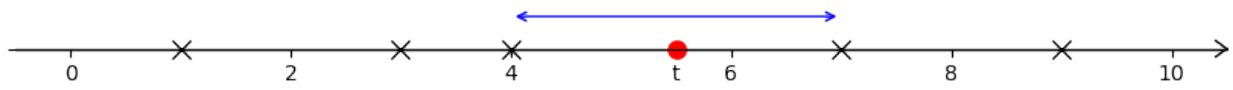

-

- **1er raisonnement :** Vu l'absence de mémoire de la loi exponentielle qui régit les temps entre les arrivées, mon temps d'attente suit une loi $\text{Exp}(\lambda)$, donc en moyenne $1/\lambda$.
- **2ème raisonnement :** J'arrive au hasard entre deux bus. Par symétrie, le temps moyen d'attente sera la moitié de la longueur typique des intervalles, soit $\frac{1}{2\lambda}$. Ce raisonnement est incorrect.

Soient $S_n = Y_1 + \cdots + Y_n$ les instants d'arrivée des bus. Soit k tel que $S_{k-1} < t \leq S_k$. Mon temps d'attente est $S_k - t$. L'erreur vient du fait que l'intervalle $[S_{k-1}, S_k]$ dans lequel on "tombe" n'est pas un intervalle typique. On a plus de chance de tomber dans un grand intervalle. Typiquement, cet intervalle est deux fois plus grand que la moyenne. L'intervalle $Y_k = S_k - S_{k-1}$ ne suit pas la loi $\text{Exp}(\lambda)$ car sa loi dépend de t.