

## Calcul Différentiel

### Dérivées Partielles et Gradient

Soit  $f : U \subset \mathbb{R}^n \rightarrow \mathbb{R}$ .

— Dérivée partielle par rapport à  $x_i$  :

$$\frac{\partial f}{\partial x_i}(x) = \lim_{t \rightarrow 0} \frac{f(x + te_i) - f(x)}{t}$$

— Gradient ( $\nabla f$ ) : Vecteur des dérivées partielles.

$$\nabla f(x) = \left( \frac{\partial f}{\partial x_1}(x), \dots, \frac{\partial f}{\partial x_n}(x) \right)^T$$

— Différentielle ( $D_x f$ ) : Application linéaire t.q.

$$f(x+h) - f(x) = D_x f(h) + o(\|h\|)$$

Pour  $f$  scalaire :  $D_x f(h) = \langle \nabla f(x), h \rangle$ .

### Hessienne et Théorème de Schwarz

— Théorème de Schwarz : Si  $f$  est  $C^2$ , alors :

$$\frac{\partial^2 f}{\partial x_i \partial x_j} = \frac{\partial^2 f}{\partial x_j \partial x_i}$$

— Matrice Hessienne ( $H_f(x)$ ) : Matrice symétrique des dérivées secondes.

$$[H_f(x)]_{ij} = \frac{\partial^2 f}{\partial x_i \partial x_j}(x)$$

### Développements Limités (Taylor)

Soit  $f$  de classe  $C^2$  sur  $U$ .

— Ordre 1 :  $f(x+h) = f(x) + \langle \nabla f(x), h \rangle + o(\|h\|)$

— Ordre 2 :

$$f(x+h) = f(x) + \langle \nabla f(x), h \rangle + \frac{1}{2} \langle H_f(x)h, h \rangle + o(\|h\|^2)$$

## Extrema Sans Contraintes

### Conditions d'Existence

#### Théorème des bornes atteintes :

Si  $K \subset \mathbb{R}^n$  est compact (fermé et borné) et  $f$  continue, alors  $f$  atteint son minimum et son maximum sur  $K$ .

### Conditions Nécessaires (Ordre 1)

Point critique :  $x$  est critique si  $\nabla f(x) = 0$ .

Si  $f$  admet un extremum local en  $x$ , alors  $x$  est un point critique.

### Conditions Suffisantes (Ordre 2)

Soit  $x$  un point critique ( $\nabla f(x) = 0$ ). On étudie  $H_f(x)$ .

—  $H_f(x)$  définie positive (valeurs propres  $> 0$ )  $\implies$  Minimum local strict.

—  $H_f(x)$  définie négative (valeurs propres  $< 0$ )  $\implies$  Maximum local strict.

— Valeurs propres de signes opposés  $\implies$  Point selle (pas d'extremum).

Cas  $n = 2$  (Notations de Monge) :

Posons  $r = \frac{\partial^2 f}{\partial x^2}, s = \frac{\partial^2 f}{\partial x \partial y}, t = \frac{\partial^2 f}{\partial y^2}$ .

—  $rt - s^2 < 0 \implies$  Point selle.

—  $rt - s^2 > 0$  et  $r > 0 \implies$  Minimum.

—  $rt - s^2 > 0$  et  $r < 0 \implies$  Maximum.

## Optimisation sous Contraintes

### Contraintes d'Égalité (Lagrange)

Minimiser  $f(x)$  sous  $g_1(x) = \dots = g_m(x) = 0$ .

#### Théorème des Multiplicateurs de Lagrange :

Si  $\tilde{x}$  est un extremum local et que les vecteurs  $\{\nabla g_i(\tilde{x})\}$  sont linéairement indépendants (contraintes qualifiées), alors  $\exists \lambda_1, \dots, \lambda_m \in \mathbb{R}$  tels que :

$$\nabla f(\tilde{x}) = \sum_{i=1}^m \lambda_i \nabla g_i(\tilde{x})$$

Le Lagrangien est défini par :

$$\mathcal{L}(x, \lambda) = f(x) - \sum_{i=1}^m \lambda_i g_i(x)$$

Condition :  $\nabla_x \mathcal{L} = 0$  et  $\nabla_\lambda \mathcal{L} = 0$ .

### Contraintes d'Inégalité (KKT)

Minimiser  $f(x)$  sous :

- $g_i(x) = 0$  ( $1 \leq i \leq m$ )
- $h_j(x) \leq 0$  ( $1 \leq j \leq p$ )

#### Conditions de Karush-Kuhn-Tucker (KKT) :

Si  $\tilde{x}$  est un minimum local et que les contraintes sont qualifiées, alors  $\exists \lambda \in \mathbb{R}^m, \mu \in \mathbb{R}^p$  tels que :

1. Stationnarité :  $\nabla f(\tilde{x}) = \sum \lambda_i \nabla g_i(\tilde{x}) + \sum \mu_j \nabla h_j(\tilde{x})$
2. Admissibilité :  $g_i(\tilde{x}) = 0$  et  $h_j(\tilde{x}) \leq 0$
3. Signe :  $\mu_j \leq 0$  (pour un min)
4. Complémentarité :  $\mu_j h_j(\tilde{x}) = 0$  ( $\mu_j = 0$  si contrainte inactive).

Note : Pour un maximum,  $\mu_j \geq 0$ .

### Qualification des contraintes

— Indépendance linéaire : Les gradients des contraintes actives sont linéairement indépendants.

— Qualification linéaire : Si les contraintes sont affines ( $Ax \leq b$ ), la qualification est automatique.

### Dualité

Problème Primal :  $p^* = \inf_x \sup_{\lambda, \mu} \mathcal{L}(x, \lambda, \mu)$ .

Problème Dual :  $d^* = \sup_{\lambda, \mu} \inf_x \mathcal{L}(x, \lambda, \mu)$  avec  $\mu \leq 0$ .

— Dualité Faible :  $d^* \leq p^*$  (toujours vrai).

— Dualité Forte :  $d^* = p^*$ . Vrai si le problème est convexe et satisfait la condition de Slater (il existe un point strictement admissible  $h_j(x) < 0$ ).

### Convexité

### Définitions et Propriétés

Un ensemble  $U$  est convexe si  $\forall x, y \in U, t \in [0, 1], (1-t)x + ty \in U$ . Une fonction  $f : U \rightarrow \mathbb{R}$  est convexe si :

$$f((1-t)x + ty) \leq (1-t)f(x) + tf(y)$$

Caractérisations ( $f \in C^1$  ou  $C^2$ ) :

1. Ordre 1 :  $f(y) \geq f(x) + \langle \nabla f(x), y - x \rangle$ .

(Le graphe est au-dessus de la tangente).

2. Ordre 2 :  $H_f(x)$  est une matrice positive ( $\forall h, \langle H_f(x)h, h \rangle \geq 0$ ).

### Théorème fondamental :

Pour une fonction convexe sur un ouvert convexe :

— Tout minimum local est un minimum global.

— Si  $\nabla f(x) = 0$ , alors  $x$  est un minimum global.

— Si  $f$  est strictement convexe, le minimum (s'il existe) est unique.

## Opérations conservant la convexité

— Somme de fonctions convexes.

— Multiplication par un scalaire positif.

— Composition  $g \circ f$  si  $f$  convexe et  $g$  convexe croissante.

— Maximum de fonctions convexes.

### Optimisation Quadratique

$$f(x) = \frac{1}{2} \langle Ax, x \rangle + \langle b, x \rangle.$$

$\nabla f(x) = Ax + b$  (si  $A$  symétrique).

$$H_f(x) = A.$$

$f$  convexe  $\iff A$  positive.

— Si  $A$  définie positive, unique min global en  $x = -A^{-1}b$ .

## Algorithmes Numériques

### Méthode de Newton

Pour résoudre  $\nabla f(x) = 0$ . Convergence quadratique (rapide) mais locale et coûteuse (inversion de matrice).

$$x_{k+1} = x_k - [H_f(x_k)]^{-1} \nabla f(x_k)$$

### Descente de Gradient

Pour minimiser  $f$ . On suit la direction opposée au gradient.

$$x_{k+1} = x_k - t_k \nabla f(x_k)$$

— Pas constant :  $t_k = t$ . Converge si  $t < 2/L$  ( $L$  = constante de Lipschitz du gradient).

— Pas optimal :  $t_k$  minimise  $\phi(t) = f(x_k - t \nabla f(x_k))$ .

— Cas quadratique ( $A$  def. pos.) : Convergence globale garantie.

### Méthode d'Uzawa

Pour optimisation quadratique sous contraintes  $Hx \leq d$ . Itération sur le multiplicateur dual  $\mu$ .

$$\begin{cases} Ax_k + b - H^T \mu_k = 0 & (\text{Minimisation en } x) \\ \mu_{k+1} = P_{\mathbb{R}_-}(\mu_k - \rho(Hx_k - d)) & (\text{Projection}) \end{cases}$$

Converge si  $0 < \rho < 2\lambda_{\min}(A)/\|H\|^2$ .

## Théorèmes Classiques

### Fonctions Implicites

Si  $g(x, y) = 0$  et  $\frac{\partial g}{\partial y} \neq 0$ , alors on peut exprimer localement  $y = \varphi(x)$ .

**Général :** Si la jacobienne partielle est inversible, on peut paramétriser la surface de contrainte.

### Inversion Locale

Si  $f$  est  $C^1$  et  $D_x f$  est inversible en  $a$ , alors  $f$  est un difféomorphisme local autour de  $a$ .

### Espace Tangent

Pour une sous-variété définie par  $g(x) = 0$ , l'espace tangent en  $x$  est l'orthogonal du gradient :

$$T_x \mathcal{S} = (\text{Vect}\{\nabla g_1(x), \dots, \nabla g_m(x)\})^\perp$$